





Trabajo Fin de Máster

Máster Universitario en Lógica,
Computación e Inteligencia Artificial

Departamento de Ciencias de la Computación e Inteligencia Artificial

# Clasificación de imágenes multi-etiqueta en entornos federados

Autor/a:
D. Manuel Mateos Gutiérrez

Tutor:
Dr. Jose María Moyano Murillo

Sevilla, XX de XXXX de 20XX

# Índice general

**Índice de figuras** **V**

**Índice de tablas** **VII**

**1. Introducción** **1**

**2. Estado del arte** **5**

2.1. Federación heterogénea . . . . . 5

2.2. Clasificación de imágenes multi-etiqueta . . . . . 6

**3. Federación con capas personalizadas y salidas heterogéneas (FedPerH)** **7**

3.1. Descripción del problema . . . . . 7

3.2. Datos de entrenamiento . . . . . 8

3.3. Arquitectura de la solución . . . . . 9

3.4. Métricas . . . . . 9

**4. Estudio experimental** **11**

4.1. Configuración de los experimentos . . . . . 11

4.2. Análisis de resultados . . . . . 12

**5. Conclusiones y trabajo futuro** **13**

5.1. Conclusiones . . . . . 13

5.2. Trabajo futuro . . . . . 14

**Bibliografía** **15**

# Índice de figuras

1.1. . . . . 2

# Índice de tablas

# 1. Introducción

Vivimos una época de auge en el campo de la Inteligencia Artificial provocado por la llegada de nuevas tecnologías en modelos de lenguaje y sistemas generativos que han creado un aumento en la demanda y la inversión, lo que ha ocasionado que se desarrollen aún más estas tecnologías, se haya normalizado su uso y se estén integrando en muchos y variados ámbitos tanto cotidianos (agentes de voz y de texto, asistentes, buscadores...) como en los negocios (asistentes a la programación, automatizaciones, sistemas integrados en medicina e investigación, logística, hostelería...).

Este florecimiento ha traído consigo también nuevos desafíos tanto en arquitectura como en regulaciones. Que cada vez haya más dispositivos recolectando y produciendo datos necesarios para entrenar modelos hace que estos sistemas tengan que adaptarse para ser más flexibles y poder dar cobertura a diferentes tipos de topologías, por ejemplo, varios dispositivos móviles pueden colaborar para entrenar una red teniendo diferentes especificaciones. Asimismo la compartición de datos personales e información sensible trae consigo la necesidad de crear sistemas más seguros, por ejemplo una persona que esté entrenando un modelo con su geolocalización pero sin tener que compartir su posición con una empresa externa. Este tipo de problemas son el germen para el desarrollo de sistemas de aprendizaje federados [1]. La idea detrás de esta arquitectura es que varios clientes entrenen modelos locales y compartan los parámetros (por ejemplo, los pesos de la red) con un servidor de manera que todos cooperan en el entrenamiento conjunto de la red mientras que los datos nunca abandonan los servidores.

Un sistema federado es un sistema de aprendizaje automático distribuido que está compuesto por varios clientes y un servidor. Para hacer una breve introducción sobre esta técnica vamos a describir el funcionamiento del aprendizaje federado centralizado aunque hay otros métodos. El proceso a alto nivel es el siguiente: El servidor inicializa la red global y envía una copia de los pesos de los nodos de la red a cada cliente, los clientes realizan un entrenamiento local con sus datos. Una vez acabado el entrenamiento local los pesos de cada red local se devuelven al servidor, que hace una agregación de los pesos para actualizar la red global, que se vuelve a

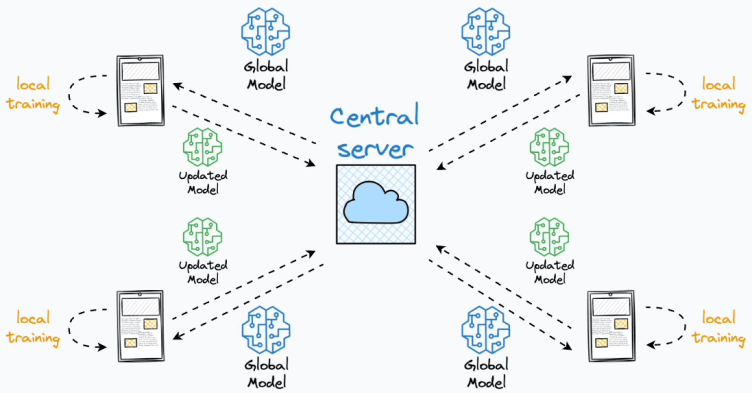



Figura 1.1:

enviar actualizada a los clientes. Podemos encontrar una representación visual de este proceso en la fig. 1.1.

Como vemos, los datos siempre se quedan en los clientes y no son compartidos con el servidor. Podemos imaginar un entorno en el que los clientes tienen datos sensibles (datos en un dispositivo personal o de pacientes en un centro sanitario) que no se desea compartir con una empresa externa o que no pueden salir de una determinada zona como por ejemplo datos de empresas de la Unión Europea que no se pueden compartir con servidores fuera de ella. A parte de la privacidad, otro beneficio es que los recursos requeridos para los entrenamientos locales son menores comparados con una estructura centralizada, de manera que el resultado de la cooperación de muchos clientes es más eficiente que si trabajasen de manera aislada con esos mismos recursos. También es importante mencionar que de esta forma se permite de manera más fácil la integración de nuevos clientes (dispositivos, empresas, entidades públicas...) con sistemas ya establecidos.

Queremos estudiar este sistema aplicado a un problema de clasificación de imágenes multi-etiqueta, a diferencia del etiquetado multi-clase el cual como salida solo tiene una única clase, en el multi-etiqueta cada imagen puede tener más de una clase lo que hace que el entrenamiento sea más complejo pero más flexible ya que en una misma predicción se pueden detectar más de una clasificación, por ejemplo reconocer varios objetos dentro de una imagen.

Sin embargo aún existen varios desafíos en el campo del aprendizaje federado. La bondad de los modelos federados está probada para datos homogéneos, pero cuando los datos son consistentes en etiquetas, características o cantidad es más fácil que los clientes al entrenarse lleguen a un máximo global. Sin embargo si hay desequilibrios en estas categorías es más fácil que lleguen a un máximo local, lo que dificulta la agregación de los pesos de las distintas redes de los clientes en el servidor.

En nuestro caso particular analizaremos la viabilidad de implementar un modelo de clasificación multi-etiqueta con datos heterogéneos dentro de un sistema federado. La idea es que cada cliente sea usado para una tarea diferente entrenando solo un subconjunto de etiquetas y se pueda beneficiar del aporte del resto de clientes.

El resto de la memoria se organiza del siguiente modo:

**2. Estado del arte.** En este capítulo se analizarán qué sistemas existen que implementen clasificación multi-etiqueta en entornos federados o qué estudios se acercan. También se definirá la base da la que partiremos para nuestra implementación.

**3. Propuesta.** Se describen los sistemas desarrollados en este trabajo.

**4. Estudio Experimental.** Se presentan los resultados de los experimentos realizados.

**5. Conclusiones y Trabajo Futuro.** Se plantean las conclusiones y futuras ampliaciones del sistema y líneas de trabajo futuro en este campo.

# 2. Estado del arte

En esta sección vamos a hacer un resumen sobre los trabajos realizados alrededor del problema de multi-etiquetado de imágenes en sistemas federados centrándonos en el problema de la heterogeneidad y cómo solucionarla.

## 2.1. Federación heterogénea

El estudio Heterogeneous Federated Learning: State-of-the-art and Research Challenges [2] realiza una clasificación de los problemas presentes en las diferentes arquitecturas de modelos federados según si la heterogeneidad es estadística, en el modelo, en las comunicaciones o en los dispositivos. Si hablamos de la heterogeneidad estadística estamos hablando de los datos y el principal problema es que no sean independientes e identicamente distribuídos (no-IID) lo que hace que el aprendizaje se reduzca considerablemente [3] [4]. Ahondando más en esta categorización pueden tener desbalance de etiquetas, desbalance de características, desbalance de calidad y desbalance de cantidad. Artículos como [5] hablan de este problema en datos médicos y atacan el problema centrándose en la normalización de los datos.

El estudio también evalúa otros tipos de heterogeneidad en la comunicación, los dispositivos y los modelos y propone diferentes soluciones para mitigar estos problemas. El caso que nos compete tiene desbalance en etiquetas ya que como hemos comentado antes cada cliente va a entrenar una tarea distinta, por lo que los datos de cada uno solo tendrán un subconjunto de las etiquetas y también desbalance en los modelos ya que cada cliente va a tener un número de etiquetas diferente por lo que la salida de la red local no será consistente entre todo el sistema. En cuanto al desbalance en el modelo se proponen varias soluciones, una de ellas es la compartición de arquitectura, que consiste en compartir parte del modelo y hacer un entrenamiento personalizado, este método es capaz de solucionar tanto la heterogeneidad estadística como la de modelo y de dispositivo al mismo tiempo [6].

Los métodos a nivel de datos pueden resolver el problema asociado a las grandes diferencias en la distribución de los datos y acelerar la convergencia reduciendo heterogeneidad estadística entre ellos. Por el contrario, los métodos a nivel de modelo buscan aprender un modelo local para cada cliente que se adapte a su distribución de datos privada, esta solución es la que queremos estudiar en este trabajo.

## 2.2. Clasificación de imágenes multi-etiqueta

En cuanto al problema de clasificación multi-etiqueta en el reciente estudio Rethinking Multi-Label Image Classification With Deep Learning: Taxonomy, Challenge, and Outlook [7] analiza el cambio de paradigma en el problema que han traido los sistemas basados en redes convolucionales y transformers y estudia como diferentes métodos derivados de estas redes han mejorado la calidad de los sistemas de aprendizaje para esta tarea. Podemos encontrar un benchmarking de diferentes arquitecturas de redes como ResNet101 [8], ViT-Base [9], ML-GCN [10], ASL [11], Q2L [12], SALGL [13], SGRE [14], and PAT [15].

En cuanto a la resolución del problema conjunto de crear un clasificador multi-etiqueta dentro de un entorno federado, como ya hemos visto anterioremente hay estudios que se centran en evitar el problema haciendo un tratamiento previo de los datos para evitar el desbalanceo, otros estudian diferentes arquitecturas de la red como Transformer-based Federated Learning for Multi-Label Remote Sensing Image Classification [16]. Sin embargo estos estudios comparten la misma red entre los clientes o se aplican sobre datos tabulados. Nuestra propuesta requiere que la distribución de los datos contenga diferente número de etiquetas y que el sistema acepte una arquitectura con diferentes redes, no hemos encontrado ningún estudio que una todos estos conceptos en una solución.

# 3. Federación con capas personalizadas y salidas heterogéneas (FedPerH)

En esta sección vamos a definir el problema que debemos solucionar, concretaremos las herramientas que usaremos basándonos en el estado del arte de la sección anterior y describiremos la arquitectura que hemos propuesto para la solución de dicho problema.

## 3.1. Descripción del problema

El problema que estamos intentando resolver es la clasificación de imágenes multi-etiqueta en un entorno federado y validar la viabilidad de que cada cliente tenga etiquetas que no estén compartidas con los demás clientes.

Como casos de uso podemos plantear un entorno en el que varios centros médicos de diferentes disciplinas quieren hacer uso de un sistema de procesado de imágenes médicas sin que estas abandonen los centros. El coste de que cada centro entrene su propio modelo es alto y requeriría un gran número de datos de entrenamiento. Para que todos los centros pudieran colaborar en entrenar un mismo modelo tendrían que agregar las imágenes médicas en un mismo servidor y esto crearía problemas de privacidad y políticas de tratamiento de datos. Un sistema federado puede solucionar estos problemas ya que los datos no abandonan los clientes y al participar todos ellos en el entrenamiento común el resultado que obtienen es mayor que el aporte que hacen al entrenamiento por separado, por lo que los recursos son usados de manera más eficiente.

Sin embargo aún tendríamos un problema y es el de la especialización de cada cliente, en el supuesto actual todos ellos deberían realizar la misma tarea pero lo

que queremos es que las tareas sean diferentes para cada uno. Por tanto antes debemos crear un desbalance en las etiquetas de los datos de entrenamiento y variar el número de clases de salida en los modelos. De esta forma nos aseguramos de que las tareas de entrenamiento son diferentes para cada cliente.

Por tanto vamos a crear un sistema federado en el que cada cliente tendrá un modelo diferente y usaremos un dataset de imágenes con una o más etiquetas para cada ejemplo.

## 3.2. Datos de entrenamiento

Para los datos de entrenamiento vamos a usar el conjunto de imágenes multi-etiqueta Corel-5k, que tiene 5000 imágenes de 50 categorías y un diccionario de 260 palabras o clases `https://www.kaggle.com/datasets/parhamsalar/corel5k`.

El dataset se compone de una carpeta con las 5000 imágenes y tres archivos csv que asignan las etiquetas a cada nombre de imagen. Lo primero que hacemos es componer tres DataFrame de Pandas, uno por cada archivo csv de manera que para cada elemento en la columna "`image_name`"tiene las imágenes en formato PIL y en la columna "`image_labels`"tiene una lista con el nombre de cada etiqueta de esa imagen. Luego los unimos en un único DataFrame ya que es más cómodo trabajar con todos los datos juntos.

Una vez tenemos un único DataFrame el siguiente paso es separarlo en dos de manera que tengamos dos conjuntos de datos con etiquetas diferentes, para ello primero contamos el número de etiquetas totales del dataset y lo ordenamos por las que más se repiten, en nuestro caso son "waterz "sky". Creamos un subconjunto de ejemplos que contienen la etiqueta "waterz eliminamos de ese subconjunto todas las etiquetas "sky", de esta manera conseguimos que la etiqueta "sky"sea exclusiva del segundo conjunto el cuál tendrá un procesado similar pero seleccionando los ejemplos que contengan "skyz eliminando la etiqueta "water".

Ya hemos conseguido dos DataFrame que contienen clases exclusivas, en este paso vamos a convertirlos al tipo Dataset para seguir trabajando con ellos y dividir cada uno en dos subconjuntos "trainz "test.[en] una distribución de 80 y 20 %. Ahora tenemos un DataSet de imágenes y etiquetas en forma de palabras que vamos a cambiar para que sean números desde 0 hasta el número de etiquetas para el conjunto water y lo mismo para sky. Seleccionamos todas las etiquetas únicas de cada conjunto y las numeramos desde 0 hasta el tamaño del conjunto de etiquetas únicas -1 y luego aplicamos una transformación al DataSet para que intercambie cada etiqueta por su identificador.

Una vez tenemos el remapeo de etiquetas lo siguente es realizar transforma-

ciones aleatorias sobre las imágenes para normalizarlas y para añadir varibilidad en el entrenamiento. Las operaciones que vamos a aplicar son reescalar a un tamaño de 32x32, volcado horizontal aleatorio, rotación aleatoria, recorte central, normalización y los conjuntos de etiquetas los vamos a poner en formato one-hot.

Por último vamos a configurar los DataLoaders que serán los conjuntos que se van a usar para el entrenamiento y la evaluación ajustando el formato para que tenga un diccionario con todas las imágenes en "`image_namez` todas las etiquetas en one-hot en "`image_name`".

Con estos DataLoaders podemos empezar a trabajar.

## 3.3. Arquitectura de la solución

## 3.4. Métricas

# 4. Estudio experimental

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Mauris id tortor eget tellus sollicitudin molestie. Morbi vehicula aliquam turpis, eget efficitur dolor rhoncus non. Integer mi odio, elementum non euismod sed, elementum eu dolor. Maecenas commodo sapien sed ultricies posuere. Ut molestie, mauris et tempor fermentum, ex massa consequat elit, eu consequat justo nibh ut augue. Sed in justo dui. Sed non molestie nisi. Ut fermentum nec ante sed ultrices. Vestibulum placerat quam urna, nec sollicitudin nibh rhoncus non. Curabitur pulvinar facilisis posuere.

## 4.1. Configuración de los experimentos

Donec eu dolor et quam porta vulputate vitae vulputate augue. Etiam fermentum, lectus vitae euismod feugiat, elit ligula luctus ante, eget commodo turpis leo vel quam. Aenean consectetur in turpis sit amet varius. Sed porta porttitor lectus, id tempus nunc suscipit vitae. Etiam blandit quam quis magna ornare pharetra. Aenean eget tortor nisi. Sed sit amet tempus eros. Phasellus pretium, nunc nec fringilla placerat, metus lectus maximus eros, nec condimentum neque ex nec orci. Vivamus facilisis at turpis sit amet maximus. Ut dolor justo, bibendum eget rhoncus eget, malesuada malesuada lacus. Suspendisse potenti.

Donec augue nulla, semper ac tempor sit amet, vehicula sed est. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Pellentesque vel convallis justo, quis feugiat velit. Etiam fermentum, risus et venenatis rhoncus, ipsum ligula congue neque, sed consectetur arcu turpis vel metus. Integer ornare turpis et luctus ullamcorper. Ut placerat a ex et consequat. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas.

## 4.2. Análisis de resultados

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Mauris id tortor eget tellus sollicitudin molestie. Morbi vehicula aliquam turpis, eget efficitur dolor rhoncus non. Integer mi odio, elementum non euismod sed, elementum eu dolor. Maecenas commodo sapien sed ultricies posuere. Ut molestie, mauris et tempor fermentum, ex massa consequat elit, eu consequat justo nibh ut augue. Sed in justo dui. Sed non molestie nisi. Ut fermentum nec ante sed ultrices. Vestibulum placerat quam urna, nec sollicitudin nibh rhoncus non. Curabitur pulvinar facilisis posuere.

Donec eu dolor et quam porta vulputate vitae vulputate augue. Etiam fermentum, lectus vitae euismod feugiat, elit ligula luctus ante, eget commodo turpis leo vel quam. Aenean consectetur in turpis sit amet varius. Sed porta porttitor lectus, id tempus nunc suscipit vitae. Etiam blandit quam quis magna ornare pharetra. Aenean eget tortor nisi. Sed sit amet tempus eros. Phasellus pretium, nunc nec fringilla placerat, metus lectus maximus eros, nec condimentum neque ex nec orci. Vivamus facilisis at turpis sit amet maximus. Ut dolor justo, bibendum eget rhoncus eget, malesuada malesuada lacus. Suspendisse potenti.

Donec augue nulla, semper ac tempor sit amet, vehicula sed est. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Pellentesque vel convallis justo, quis feugiat velit. Etiam fermentum, risus et venenatis rhoncus, ipsum ligula congue neque, sed consectetur arcu turpis vel metus. Integer ornare turpis et luctus ullamcorper. Ut placerat a ex et consequat. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas.

# 5. Conclusiones y trabajo futuro

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Mauris id tortor eget tellus sollicitudin molestie. Morbi vehicula aliquam turpis, eget efficitur dolor rhoncus non. Integer mi odio, elementum non euismod sed, elementum eu dolor. Maecenas commodo sapien sed ultricies posuere. Ut molestie, mauris et tempor fermentum, ex massa consequat elit, eu consequat justo nibh ut augue. Sed in justo dui. Sed non molestie nisi. Ut fermentum nec ante sed ultrices. Vestibulum placerat quam urna, nec sollicitudin nibh rhoncus non. Curabitur pulvinar facilisis posuere.

## 5.1. Conclusiones

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Mauris id tortor eget tellus sollicitudin molestie. Morbi vehicula aliquam turpis, eget efficitur dolor rhoncus non. Integer mi odio, elementum non euismod sed, elementum eu dolor. Maecenas commodo sapien sed ultricies posuere. Ut molestie, mauris et tempor fermentum, ex massa consequat elit, eu consequat justo nibh ut augue. Sed in justo dui. Sed non molestie nisi. Ut fermentum nec ante sed ultrices. Vestibulum placerat quam urna, nec sollicitudin nibh rhoncus non. Curabitur pulvinar facilisis posuere.

Donec eu dolor et quam porta vulputate vitae vulputate augue. Etiam fermentum, lectus vitae euismod feugiat, elit ligula luctus ante, eget commodo turpis leo vel quam. Aenean consectetur in turpis sit amet varius. Sed porta porttitor lectus, id tempus nunc suscipit vitae. Etiam blandit quam quis magna ornare pharetra. Aenean eget tortor nisi. Sed sit amet tempus eros. Phasellus pretium, nunc nec fringilla placerat, metus lectus maximus eros, nec condimentum neque ex nec orci. Vivamus facilisis at turpis sit amet maximus. Ut dolor justo, bibendum eget rhoncus eget, malesuada malesuada lacus. Suspendisse potenti.

Donec augue nulla, semper ac tempor sit amet, vehicula sed est. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Pellentesque vel convallis justo, quis feugiat velit. Etiam fermentum, risus et venenatis rhoncus, ipsum ligula congue neque,

sed consectetur arcu turpis vel metus. Integer ornare turpis et luctus ullamcorper. Ut placerat a ex et consequat. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas.

## 5.2. Trabajo futuro

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Mauris id tortor eget tellus sollicitudin molestie. Morbi vehicula aliquam turpis, eget efficitur dolor rhoncus non. Integer mi odio, elementum non euismod sed, elementum eu dolor. Maecenas commodo sapien sed ultricies posuere. Ut molestie, mauris et tempor fermentum, ex massa consequat elit, eu consequat justo nibh ut augue. Sed in justo dui. Sed non molestie nisi. Ut fermentum nec ante sed ultrices. Vestibulum placerat quam urna, nec sollicitudin nibh rhoncus non. Curabitur pulvinar facilisis posuere.

Donec eu dolor et quam porta vulputate vitae vulputate augue. Etiam fermentum, lectus vitae euismod feugiat, elit ligula luctus ante, eget commodo turpis leo vel quam. Aenean consectetur in turpis sit amet varius. Sed porta porttitor lectus, id tempus nunc suscipit vitae. Etiam blandit quam quis magna ornare pharetra. Aenean eget tortor nisi. Sed sit amet tempus eros. Phasellus pretium, nunc nec fringilla placerat, metus lectus maximus eros, nec condimentum neque ex nec orci. Vivamus facilisis at turpis sit amet maximus. Ut dolor justo, bibendum eget rhoncus eget, malesuada malesuada lacus. Suspendisse potenti.

# Bibliografía


[1] Qiang Yang, Yang Liu, Yong Cheng, Yan Kang, Tianjian Chen, and Han Yu. *Federated Learning*. Morgan & Claypool publishers, 2019.

[2] Mang Ye, Xiuwen Fang, Bo Du, Pong C. Yuen, and Dacheng Tao. Heterogeneous federated learning: State-of-the-art and research challenges. *ACM Comput. Surv.*, 56(3), October 2023.

[3] Yue Zhao, Meng Li, Liangzhen Lai, Naveen Suda, Damon Civin, and Vikas Chandra. Federated learning with non-iid data. 2018.

[4] Marcos F. Criado, Fernando E. Casado, Roberto Iglesias, Carlos V. Regueiro, and Senén Barro. Non-iid data and continual learning processes in federated learning: A long road ahead. 2021.

[5] Zhaobin Sun, Nannan Wu, Junjie Shi, Li Yu, Xin Yang, Kwang-Ting Cheng, and Zengqiang Yan. Fedmlp: Federated multi-label medical image classification under task heterogeneity. 2024.

[6] Manoj Ghuhan Arivazhagan, Vinay Aggarwal, Aaditya Kumar Singh, and Sunav Choudhary. Federated learning with personalization layers. 2019.

[7] Xuelin Zhu, Xiu-Shen Wei, Jiawei Ge, Shuai Xu, and Bing Wang. Rethinking multi-label image classification with deep learning: Taxonomy, challenge, and outlook. 2026.

[8] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. 2015.

[9] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. 2021.

[10] Zhao-Min Chen, Xiu-Shen Wei, Peng Wang, and Yanwen Guo. Multi-label image recognition with graph convolutional networks. 2019.

[11] Emanuel Ben-Baruch, Tal Ridnik, Nadav Zamir, Asaf Noy, Itamar Friedman, Matan Protter, and Lihi Zelnik-Manor. Asymmetric loss for multi-label classification. 2021.

[12] Shilong Liu, Lei Zhang, Xiao Yang, Hang Su, and Jun Zhu. Query2label: A simple transformer way to multi-label classification. 2021.

[13] Xuelin Zhu, Jian Liu, Weijia Liu, Jiawei Ge, Bo Liu, and Jiuxin Cao. Scene-aware label graph learning for multi-label image classification. pages 1473–1482, 2023.

[14] Xuelin Zhu, Jianshu Li, Jiuxin Cao, Dongqi Tang, Jian Liu, and Bo Liu. Semantic-guided representation enhancement for multi-label image classification. *IEEE Transactions on Circuits and Systems for Video Technology*, 34(10):10036–10049, 2024.

[15] Ming-Kun Xie, Jia-Hao Xiao, Pei Peng, Gang Niu, Masashi Sugiyama, and Sheng-Jun Huang. Counterfactual reasoning for multi-label image classification via patching-based training. 2024.

[16] Barış Büyüktaş, Kenneth Weitzel, Sebastian Völkers, Felix Zailskas, and Begüm Demir. Transformer-based federated learning for multi-label remote sensing image classification. 2024.