



Trabajo Fin de Máster

Máster Universitario en Lógica,
Computación e Inteligencia Artificial

Departamento de Ciencias de la Computación e Inteligencia Artificial

Clasificación de imágenes multi-etiqueta en entornos federados

Autor/a:
D. Manuel Mateos Gutiérrez

Tutor:
Dr. Jose María Moyano Murillo

Sevilla, XX de XXXX de 20XX

Índice general

Índice de figuras **V**

Índice de tablas **VII**

1. Introducción **1**

2. Estado del arte **5**

2.1. Aprendizaje Federado 5

2.1.1. Aprendizaje federado heterogéneo 7

2.2. Clasificación multi-etiqueta 8

2.2.1. Descripción formal del MLC 9

2.2.2. Eligiendo modelo para clasificación multi-etiqueta 10

3. Federación con capas personalizadas y salidas heterogéneas (FedPerH) **11**

3.1. Arquitectura de la solución 11

3.2. FedPer 12

3.3. Modelo 13

3.4. Modificaciones 14

4. Estudio experimental **17**

4.1. Datos de entrenamiento y evaluación 17

4.2. Métricas de evaluación 18
4.2.1. Label ranking average precision 19
4.2.2. Matriz de confusión 19
4.2.3. F1 Score 23
4.3. Configuración de los experimentos 23
4.4. Análisis de resultados 25

5. Conclusiones y trabajo futuro **33**
5.1. Conclusiones 33
5.2. Trabajo futuro 34

Bibliografía **36**

Índice de figuras

2.1. Entrenamiento federado cliente-servidor 6

2.2. Ejemplos de clasificación binaria y multi-clase 8

2.3. Ejemplo de clasificación multi-etiqueta 9

2.4. Ejemplo de conjunto de datos multi-etiqueta. Figura obtenida de [1] 9

3.1. Ejemplo de los modelos en cada cliente y el servidor; en verde, las capas del modelo que son comunes a todos los clientes, mientras que en otro color se indican la parte del modelo (capas de salida) que son únicas para cada uno de ellos, y que no se comparten con el servidor. 13

4.1. F1 Federado contra no federado para el Cliente 1 25

4.2. F1 Federado contra no federado para el Cliente 2 25

4.3. F1 Federado contra no federado para el Cliente 3 26

4.4. F1 Federado contra no federado para el Cliente 4 26

4.5. Promedio de F1 entre los cuatro clientes federados, respecto a la media de F1 en los casos centralizados 27

Índice de tablas

4.1. Distribución de etiquetas 18
4.2. Ejemplos 20
4.3. Predicciones 20
4.4. Configuración del experimento 24
4.5. Métricas para el cliente 1 centralizado en la ronda 100 28
4.6. Métricas para el cliente 1 federado en la ronda 100 28
4.7. Métricas para el cliente 2 centralizado en la ronda 100 29
4.8. Métricas para el cliente 2 federado en la ronda 100 29
4.9. Métricas para el cliente 3 centralizado en la ronda 100 29
4.10. Métricas para el cliente 3 federado en la ronda 100 30
4.11. Métricas para el cliente 4 centralizado en la ronda 100 30
4.12. Métricas para el cliente 4 federado en la ronda 100 30
4.13. Métricas promedio en la ronda 100 para el caso centralizado 31
4.14. Métricas promedio en la ronda 100 para el caso federado 31

1. Introducción

Vivimos una época de auge en el campo de la Inteligencia Artificial provocado por la llegada de nuevas tecnologías en modelos de lenguaje y sistemas generativos que han creado un aumento en la demanda y la inversión, lo que ha ocasionado que se desarrollen aún más estas tecnologías, se haya normalizado su uso y se estén integrando en muchos y variados ámbitos tanto cotidianos (agentes de voz y de texto, asistentes, buscadores, etc.) como en los negocios (asistentes a la programación, automatizaciones, sistemas integrados en medicina e investigación, logística, hostelería, etc.).

Este florecimiento ha traído consigo también nuevos desafíos tanto en arquitectura como en regulaciones. Que cada vez haya más dispositivos recolectando y produciendo datos necesarios para entrenar modelos hace que estos sistemas tengan que adaptarse para ser más flexibles y poder dar cobertura a diferentes tipos de topologías, por ejemplo, varios dispositivos móviles pueden colaborar para entrenar una red teniendo diferentes especificaciones. Asimismo la compartición de datos personales e información sensible trae consigo la necesidad de crear sistemas más seguros, por ejemplo una persona que esté entrenando un modelo con su geolocalización pero sin tener que compartir su posición con una empresa externa. Este tipo de problemas son el germen para el desarrollo de sistemas de aprendizaje federados [2].

La idea detrás de esta arquitectura es que varios clientes entrenen modelos locales y compartan los parámetros (por ejemplo, los pesos de la red) con un servidor de manera que todos cooperan en el entrenamiento conjunto de la red mientras que los datos nunca abandonan los clientes. Podemos imaginar un entorno en el que los clientes tienen datos sensibles (datos en un dispositivo personal o de pacientes en un centro sanitario) que no se desea compartir con una empresa externa o que no pueden salir de una determinada zona, como por ejemplo datos de empresas de la Unión Europea que no se pueden compartir con servidores fuera de ella. A parte de la privacidad, otro beneficio es que los recursos requeridos para los entrenamientos locales son menores comparados con una estructura centralizada, de manera que el resultado de la cooperación de muchos clientes es más eficiente

que si trabajasen de manera aislada con esos mismos recursos. También es importante mencionar que de esta forma se permite de manera más fácil la integración de nuevos clientes (dispositivos, empresas, entidades públicas...) con sistemas ya establecidos.

Como caso de uso podemos plantear un entorno en el que varios centros médicos de diferentes disciplinas quieren hacer uso de un sistema de procesado de imágenes médicas sin que estas abandonen los centros. El coste de que cada centro entrene su propio modelo es alto y requeriría un gran número de datos de entrenamiento. Para que todos los centros pudieran colaborar en entrenar un mismo modelo tendrían que agregar las imágenes médicas en un mismo servidor y esto crearía problemas de privacidad y políticas de tratamiento de datos. Un sistema federado puede solucionar estos problemas, ya que los datos no abandonan los clientes y al participar todos ellos en el entrenamiento común el resultado que obtienen es mayor que el aporte que hacen al entrenamiento por separado, por lo que los recursos son usados de manera más eficiente.

Sin embargo aún tendríamos un problema y es el de la especialización de cada cliente. En el supuesto actual todos ellos deberían realizar la misma tarea, pero podría haber casos en los que las tareas específicas sean diferentes para cada uno, aun compartiendo características comunes en el aprendizaje. Por ejemplo, varios clientes que quieran realizar clasificación de imágenes, pero cada uno disponga de fotos de distinta tipología o quieran detectar diferentes conjuntos de objetos. Mientras que la tarea es común en todos, las clases o etiquetas a predecir son específicas de cada cliente. En concreto, en el caso de que cada imagen pueda estar asociada con más de una clase o etiqueta al mismo tiempo, hablaríamos de clasificación multi-etiqueta [1].

Además de todos sus beneficios aún existen varios desafíos en el campo del aprendizaje federado. La bondad de los modelos federados está probada para datos homogéneos, pero cuando los datos son consistentes en etiquetas, características o cantidad es más fácil que los clientes al entrenarse lleguen a un óptimo global. Sin embargo si hay desequilibrios en estas categorías es más fácil que lleguen a un óptimo local, lo que dificulta la agregación de los pesos de las distintas redes de los clientes en el servidor, o incluso que la agregación de pesos de modelos que divergen en sus datos de origen no conlleve mejora alguna en cada una de las partes por separado.

En nuestro caso particular analizaremos la viabilidad de implementar un modelo de clasificación multi-etiqueta (donde cada ejemplo puede categorizarse en más de una clase o etiqueta al mismo tiempo) con datos heterogéneos dentro de un sistema federado. La idea es que cada cliente sea usado para una tarea diferente entrenando sobre un subconjunto distinto de etiquetas y se pueda beneficiar del aporte del resto de clientes.

El resto de la memoria se organiza del siguiente modo:

2. Estado del arte. En este capítulo se analizarán qué sistemas existen que implementen clasificación multi-etiqueta en entornos federados o qué estudios se acercan. También se definirá la base da la que partiremos para nuestra implementación.

3. Propuesta. Se describe la propuesta de algoritmo federado para entornos de clasificación multi-etiqueta desarrollado en este trabajo.

4. Estudio Experimental. Se presenta el marco y configuración experimental, y se muestran y analizan los resultados de los experimentos realizados.

5. Conclusiones y Trabajo Futuro. Se plantean las conclusiones y futuras ampliaciones del sistema y líneas de trabajo futuro en este campo.

2. Estado del arte

En esta sección explicaremos los elementos necesarios para la resolución del problema propuesto. Haremos una explicación en profundidad de los sistemas de aprendizaje federados y de la clasificación multi-etiqueta.

2.1. Aprendizaje Federado

En aprendizaje automático clásico tenemos un modelo que entrenamos con una serie de datos para que realice una tarea que puede ser reconocer objetos en una imagen, controlar la reacción de un sistema ante una situación o jugar a un juego. En la práctica estos datos no se generan en la máquina dónde entrenamos al modelo sino que pueden venir de un dispositivo móvil, unos sensores o un micrófono. Estos datos también pueden venir no de una única fuente sino de varios lugares que recopilen información para realizar una tarea en conjunto. La aproximación más común ante esta estructura de datos es unir todas las fuentes en un lugar centralizado y tratarlas para crear un único conjunto de datos y usarlo para realizar el entrenamiento de nuestro modelo.

Este enfoque no puede usarse en todos los casos, como por ejemplo cuando los datos no pueden compartirse con el servidor central debido a regulaciones, preferencias de privacidad o simplemente que el volumen de datos es tan grande que el servidor no es capaz de procesarlos todos entre muchos otros ejemplos.

Frente a estos problemas nace el paradigma de aprendizaje federado [2], el cuál invierte esta estructura de manera que lleva el entrenamiento a los datos. Esto nos permite aplicar el campo de aplicación de los sistemas de aprendizaje automático a lugares donde antes era difícil o imposible debido a la naturaleza de los datos, como detección de fraude financiero haciendo que varias entidades bancarias cooperen en el aprendizaje, o mejorar modelos médicos agregando el entrenamiento de diferentes sistemas sanitarios sin que las normas de privacidad se vean comprometidas.

Hay varias aproximaciones para llevar a cabo el aprendizaje federado, como la arquitectura *peer to peer*, donde todos los nodos comparten entre ellos el resultado del entrenamiento de los demás. En este trabajo nos centraremos en explicar el aprendizaje federado en arquitectura cliente-servidor, que es a su vez, el escenario más extendido [3]. En este escenario, primero el servidor inicializa el modelo global con pesos aleatorios y se envía a todos los clientes, asegurándose de esta manera que todos los clientes partan de los mismos parámetros. Luego cada cliente entrena su modelo local, que es una copia del modelo global con sus datos locales. Este entrenamiento no se realiza hasta la convergencia del modelo, sino solo realiza unos pocos pasos de entrenamiento. Una vez actualizado el modelo local de cada cliente, estos envían la actualización al servidor, ya sean los pesos o los gradientes. El servidor recibe una versión diferente del modelo inicial por cada cliente que ha participado en la ronda de entrenamiento. En este punto recordamos que el objetivo es que los clientes colaboren con sus entrenamientos parciales a actualizar un modelo global, para ello el servidor realiza una operación de unificación de todas las versiones del modelo que le han mandado mediante un proceso que llamamos agregación. El método más básico se conoce como *Federated Averaging* [4] abreviado como *FedAvg*. Este proceso realiza una media ponderada sobre los pesos de los diferentes modelos en base al número de ejemplos que han usado en el entrenamiento para asegurarse de que cada ejemplo que ha participado tiene la misma influencia. Una vez finalizada la agregación, el servidor envía el nuevo modelo a cada uno de los clientes. Este proceso se vuelve a ejecutar en bucle hasta que los modelos locales alcanzan la convergencia o un número de rondas prefijado. Este proceso está ilustrado en la Figura 2.1.

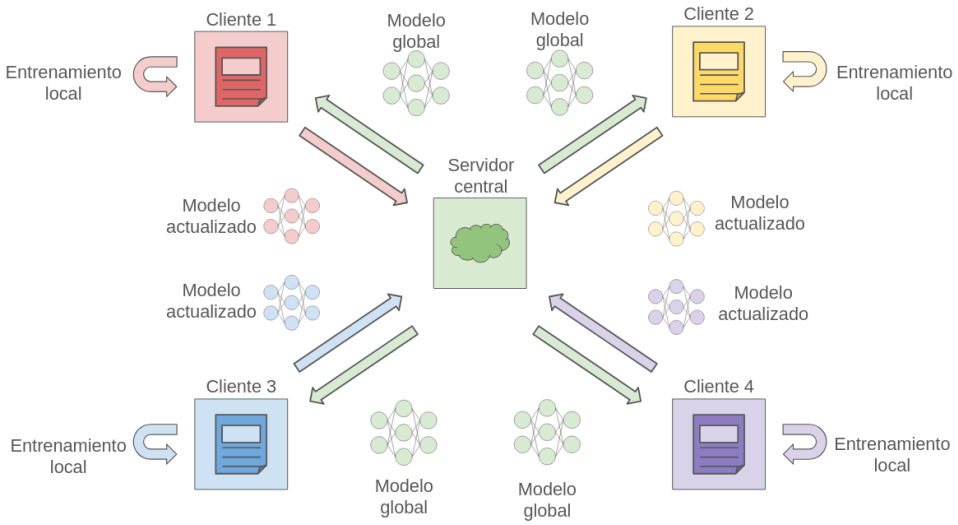


Figura 2.1: Entrenamiento federado cliente-servidor

2.1.1. Aprendizaje federado heterogéneo

En [5] se realiza una clasificación de los problemas presentes en las diferentes arquitecturas de modelos federados según si la heterogeneidad es estadística, en el modelo, en las comunicaciones o en los dispositivos. Si hablamos de la heterogeneidad estadística estamos hablando de los datos y el principal problema es que no sean independientes e identicamente distribuídos (no-IID), lo que hace que el aprendizaje se reduzca considerablemente [6] [7]. Ahondando más en esta categorización, pueden tener desbalance de etiquetas, desbalance de características, desbalance de calidad y desbalance de cantidad. Artículos como [8] hablan de este problema en datos médicos y atacan el problema centrándose en la normalización de los datos.

El estudio también evalúa otros tipos de heterogeneidad en la comunicación, los dispositivos y los modelos y propone diferentes soluciones para mitigar estos problemas. El caso que nos compete tiene desbalance en etiquetas, ya que como hemos comentado antes, aunque todos los clientes tienen como objetivo la misma tarea principal (el etiquetado de imágenes), cada uno de ellos posee un subconjunto de etiquetas diferente. Además, también podemos considerar desbalance en los modelos, ya que cada cliente va a tener un número de etiquetas diferente, por lo que la salida de la red local no será consistente entre todo el sistema. En cuanto al desbalance en el modelo se proponen varias soluciones, una de ellas es la compartición de arquitectura, que consiste en compartir parte del modelo y hacer un entrenamiento personalizado. Este método es capaz de solucionar tanto la heterogeneidad estadística como la de modelo y de dispositivo al mismo tiempo [9].

Los métodos a nivel de datos pueden resolver el problema asociado a las grandes diferencias en la distribución de los datos y acelerar la convergencia reduciendo heterogeneidad estadística entre ellos. Por el contrario, los métodos a nivel de modelo buscan aprender un modelo local para cada cliente que se adapte a su distribución de datos privada como *Backbone Sharing* que únicamente comparte una parte del modelo manteniendo capas personalizadas en el cliente. En concreto, esta solución es la que estudiaremos en este trabajo.

2.2. Clasificación multi-etiqueta

Una de las tareas más extendidas en el ámbito del aprendizaje automático es la de la clasificación, ya sea de textos, imágenes o cualquier otro tipo de conjunto de información. La tarea consiste en crear un modelo en base a las características del conjunto de datos que vayamos a procesar, para que realice una predicción sobre las clases asignadas a esos datos. Los ejemplos más comunes son la clasificación binaria y la clasificación multi-clase Figura 2.2. En la clasificación binaria asignamos un valor binario a los datos de entrada, por ejemplo un sistema que detecte si un correo es spam o no. La clasificación multi-clase define una serie de elementos de los cuales se debe elegir el que sea más probable que sea relacionado con los datos que estamos evaluando, por ejemplo detectar qué tipo de animal aparece en una foto.



Figura 2.2: Ejemplos de clasificación binaria y multi-clase

En el mundo real existen muchos escenarios donde se requiere una clasificación múltiple en la misma tarea, por ejemplo detectar diferentes patologías en una imagen médica, añadir distintas categorías o temas a un texto, detectar diferentes objetos en un vídeo en tiempo real, etcétera. En situaciones donde un mismo conjunto de datos pueden clasificarse con más de una clase, como en la Figura 2.3, donde aparecen dos animales diferentes, la clasificación multi-clase provocaría una pérdida de información. Debido a esto la clasificación multi-etiqueta es un campo que se ha desarrollado mucho en los últimos años.



Figura 2.3: Ejemplo de clasificación multi-etiqueta

2.2.1. Descripción formal del MLC

Siendo $\mathcal{D}$ un dataset multi-etiqueta compuesto por un conjunto de m instancias, y definido como $\mathcal{D} = \{(x_i, Y_i)|1 \leq i \leq m\}$. Siendo $\mathcal{X} = X_1 \times \cdots \times X_d$ el espacio de entrada de dimensión d, e $\mathcal{Y} = \{\lambda_1, \lambda_2, \ldots, \lambda_q\}$ el espacio compuesto por $q > 1$ etiquetas. Cada instancia multi-etiqueta está compuesta por un vector de entrada xi y un conjunto de etiquetas relevantes asociadas a él $Y_i \subseteq Y$. En la Figura 2.4, podemos ver un ejemplo de un conjunto de datos multi-etiqueta. Como podemos observar cada ejemplo está etiquetado con una o más etiquetas de manera simultánea.

Instance	Features	Labels				
		λ_1	λ_2	λ_3	...	λ_q
#1	$\mathbf{x}_1$	0	1	0	...	0
#2	$\mathbf{x}_2$	1	0	1	...	1
#3	$\mathbf{x}_3$	0	1	0	...	1
#4	$\mathbf{x}_4$	0	1	0	...	0
#5	$\mathbf{x}_5$	0	1	1	...	0
...	...			...		
#m	$\mathbf{x}_m$	1	0	1	...	1

Figura 2.4: Ejemplo de conjunto de datos multi-etiqueta. Figura obtenida de [1]

El objetivo del MLC es construir un modelo predictivo $h : \mathcal{X} \to 2^{\mathcal{Y}}$ que ofrezca un conjunto de etiquetas relevantes para una instancia desconocida. Por tanto, para cada $x \in \mathcal{X}$, se proporciona una bipartición $\hat{b} = (\hat{Y}, \overline{\hat{Y}})$ del espacio de etiquetas $\mathcal{Y}$, donde $\hat{Y} = h(x)$ es el conjunto de etiquetas relevantes e $\overline{\hat{Y}}$ el conjunto de irrelevantes. Esta bipartición también se puede dar como un vector binario $\hat{b} = \{0, 1\}^q$, indicando si cada etiqueta es relevante (1) o no (0).

2.2.2. Eligiendo modelo para clasificación multi-etiqueta

Para la implementación de un clasificador multi-etiqueta, y asumiendo que buscamos un modelo de red neuronal basado en pesos fácilmente aplicable en un entorno federado, debemos elegir qué arquitectura de red usaremos. Vamos a revisar las opciones que tenemos, por ejemplo en [10] se analiza el cambio de paradigma en el problema que han traído los sistemas basados en redes convolucionales y transformers y estudia como diferentes métodos derivados de estas redes han mejorado la calidad de los sistemas de aprendizaje para esta tarea. Podemos encontrar un benchmarking de diferentes arquitecturas de redes como ResNet101 [11], ViT-Base [12], ML-GCN [13], ASL [14], Q2L [15], SALGL [16], SGRE [17], and PAT [18]. Por simplicidad y su uso tan extendido usaremos ResNet en nuestra implementación.

En cuanto a la resolución del problema conjunto de crear un clasificador multi-etiqueta dentro de un entorno federado, como ya hemos visto anterioremente hay estudios que se centran en evitar el problema haciendo un tratamiento previo de los datos para evitar el desbalanceo, mientras otros estudian diferentes arquitecturas de la red como en [19]. Sin embargo estos estudios comparten la misma red entre los clientes o se aplican sobre datos tabulados. Nuestra propuesta requiere que la distribución de los datos contenga diferente número de etiquetas y que el sistema acepte una arquitectura con diferentes redes. Tras una búsqueda bibliográfica, no hemos encontrado ningún estudio que una todos estos conceptos en una solución, radicando ahí por tanto la principal novedad de este trabajo.

3. Federación con capas personalizadas y salidas heterogéneas (FedPerH)

En esta sección vamos a proponer una solución al problema de clasificación multi-etiqueta en entornos federados. Explicaremos la arquitectura que se va a usar para el algoritmo, la base del mismo y las modificaciones que hemos realizado.

3.1. Arquitectura de la solución

Supongamos que tenemos N clientes y cada uno realizará una tarea de clasificación con un conjunto de etiquetas diferente. Estos clientes quieren realizar el entrenamiento del modelo que usarán para realizar la tarea de manera cooperativa pero sin compartir los datos. Para que realicen esta tarea vamos a usar modelos personalizados que contarán con una parte común, que es la que se compartirá con el servidor, y un conjunto de capas personalizadas que quedarán en los clientes. De esta manera, parte del modelo tendrá una función general y compartida entre los demás nodos, mientras que cada uno cada uno de ellos entrenará la parte específica a su tarea únicamente de manera local..

El servidor crea el modelo compartido y lo envía a cada uno de los clientes. Una vez lo reciben, cada cliente añade las capas personalizadas para completarlo, en las que se incluye la salida del modelo según el número de etiquetas que tengan los datos para ese cliente. Los clientes una vez tienen el modelo completo realizan varias épocas de entrenamiento local, guardan el estado del modelo, y separan la parte común y las capas personalizadas. El estado actualizado de las capas personalizadas se almacena en el cliente mientras que la parte común se devuelve al servidor. El servidor recibe la parte común de todos los clientes las cuales tendrán un estado distinto para cada uno ya que se han entrenado con datos diferentes y las agre-

ga asignando un peso a cada modelo según el número de datos de entrenamiento. Como resultado de esta agregación obtenemos un modelo común actualizado que se enviará a cada uno de los clientes para volver a iniciar el proceso hasta que se realicen un número determinado de rondas o hasta que el modelo converja.

En otros sistemas federados es común que el modelo se comparta al completo con el servidor ya que el entrenamiento de las capas de salida es relevante para todos los clientes. En nuestro caso esto no se cumple ya que la activación de la salida es única para cada cliente y la posición de la etiqueta "agua" en un cliente correspondería a un objeto distinto en otro. Por ello el modelo que compartimos con el servidor está truncado y no serviría para usarse por sí mismo, ya que no tiene una capa de salida que se ajuste a los datos de los clientes.

3.2. FedPer

El aprendizaje federado necesita una insfraestructura que permita mover modelos de un lado a otro entre el servidor y los clientes, ejecutar el entrenamiento con los datos locales y agregar los modelos actualizados. Para evitar la implementación de todo el sistema desde cero vamos a usar de base el entorno de trabajo para aprendizaje federado Flower [1], que nos provee de esta infraestructura. Más en concreto haremos uso del baseline de Flower FedPer [2], una implementación de [9] el cual propone una aplicación del método de *Backbone Sharing* que vimos en [5]. FedPer es un entorno simulado que crea el servidor y los clientes, en el servidor se instancia el modelo global con dos partes diferenciadas llamadas *cuerpo* y *cabeceras*: el *cuerpo* corresponde a la parte del modelo que va a ser compartida y las *cabeceras* son las capas que van a ser entrenadas en el cliente pero no van a devolverse. El servidor inicializa el *cuerpo* y se envía a cada uno de los clientes los cuales actualizan sus modelos locales con él. Cada modelo local se entrena con sus datos y los *cuerpos* actualizados se devuelven al servidor el cuál realiza la operación de agregación, que en nuestro caso será FedAvg [4], pero solo con la parte del modelo enviada por los clientes. Una vez actualizado el modelo global se devuelve a los clientes para la siguiente ronda de entrenamiento (Figura 3.1).

FedPer y Flower también nos dan herramientas para la agregación de métricas de entrenamiento y evaluación.

[1] `https://flower.ai/`

[2] `https://flower.ai/docs/baselines/fedper.html`

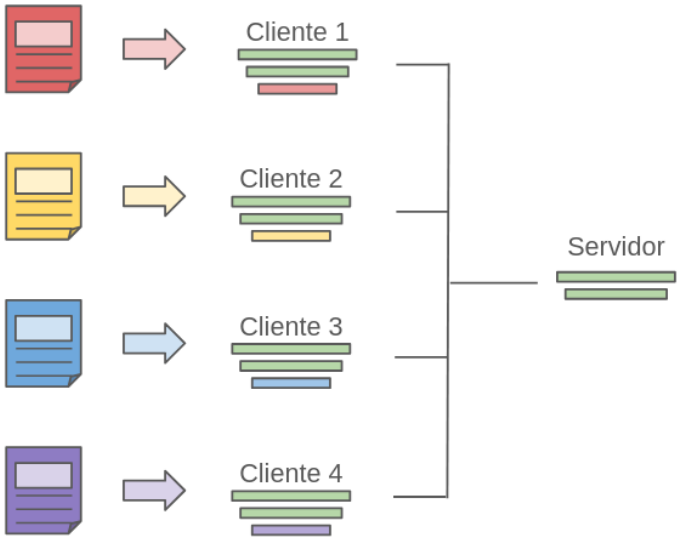


Figura 3.1: Ejemplo de los modelos en cada cliente y el servidor; en verde, las capas del modelo que son comunes a todos los clientes, mientras que en otro color se indican la parte del modelo (capas de salida) que son únicas para cada uno de ellos, y que no se comparten con el servidor.

3.3. Modelo

Para las capas compartidas con el servidor necesitamos un modelo que nos ayude con la tarea de procesamiento de imágenes. Las redes convolucionales [20] son ideales para en tratamiento de imágenes, ya que son capaces de realizar operaciones sobre las matrices de datos multi-dimensionales que la conforman. Por lo general, cuantas más capas tengan mejor será el rendimiento, sin embargo si son muy profundas aparece el problema del desvanecimiento del gradiente. Al entrenar estas redes la función de *backpropagation* envía una señal de error desde la salida hacia la entrada de la red para ajustar los pesos; si la red tiene muchas capas este error se va multiplicando por números cada vez más pequeños hasta que las primeras capas apenas se ajustan, lo que no les permite aprender. En [11] se propone la red ResNet la cual resuelve el problema del desvanecimiento del gradiente mediante capas residuales. Estas capas funcionan de manera que la salida se calcula en base a la entrada por lo que la transformación que realiza la capa se convierte en un problema de optimización el cuál es mucho más sencillo de realizar puesto que la corrección es menor. Estas capas residuales permiten que podamos tener redes más profundas, y se han usado en problemas de tratamiento de imágenes como AlphaGo [21] y AlphaFold [22]. Nosotros vamos a usar ResNet34 la cuál tiene 34 capas residuales, que se encargará de de las funciones comunes a las diferentes tareas. Aunque nosotros usemos ResNet34 para la base de nuestro modelo, la

arquitectura es independiente de éste, por lo que se podría usar otra red.

Las capas personalizadas de cada cliente se encargarán de la parte específica. Para las capas personalizadas vamos a añadir para cada servidor dos capas convolucionales y una capa linear para la salida con un nodo para cada etiqueta.

3.4. Modificaciones

FedPer está adaptado para la implementación de un sistema que realiza una clasificación de imágenes multi-clase. Las modificaciones que debemos realizar son para que este mismo sistema sea capaz de clasificar imágenes multi-etiqueta.

La primera modificación es en referencia a los datos. FedPer asume que cada uno de los clientes entrena imágenes con una serie de etiquetas distintas que se eligen de manera aleatoria entre todas las del conjunto, pero la salida de todas las capas personalizadas de los clientes tienen de dimensión el número de etiquetas totales del conjunto de datos. Nuestro caso es diferente, al reducir la dimensión de la salida de las capas personalizadas únicamente al número de etiquetas del conjunto de datos de cada cliente (que son, en esencia, de las que el cliente en cuestión tiene registro, al no tener información alguna sobre las etiquetas del resto de clientes por temas de privacidad). Por tanto, y por motivos de simulación del entorno federado, debemos realizar un tratamiento previo al conjunto de datos multi-etiqueta que vamos a usar para prepararlo para esta tarea. Primero realizamos una selección de las etiquetas que tendrá cada conjunto y nos aseguramos que no están presente en el resto. Luego debemos actualizar los índices de las etiquetas en cada conjunto para que tomen valores entre 0 y n siendo n el número de etiquetas menos uno en las imágenes de ese cliente. Esto debemos hacerlo para que la salida nos de siempre un vector de dimensión n.

La segunda modificación tiene que ver con las capas personalizadas. En FedPer las capas personalizadas no se comparten desde los clientes al servidor, pero es este el que las inicializa con los mismos pesos para todos los clientes. En nuestro caso vamos a dejar que cada cliente inicialice sus capas personalizadas con pesos distintos (ya que ni el servidor tiene información sobre qué etiquetas o cuantas tiene cada cliente), y el servidor solamente inicializará la parte común del modelo.

La tercera modificación se relaciona con el entrenamiento y más concretamente con la función de pérdida. FedPer usa *CrossEntropyLoss* para el entrenamiento multi-clase. En nuestro caso el modelo como salida nos da un vector de dimensión n con valores entre menos infinito e infinito o *logits*. La función *BCEWithLogits* nos permite aplicar la función *Binary Cross Entropy* que evalúa cada clase de manera independiente junto con la *sigmoid* para poder trabajar con esos *logits*.

Por último hemos adaptado la evaluación del modelo. Originalmente, al tratar con imágenes multi-clase solamente debía tener una clase activa para cada ejemplo y por ello comprobaba que la predicción y la salida real fueran idénticas. En nuestro caso debemos introducir técnicas de evaluación para clasificación multi-etiqueta la cuál conlleva ciertas dificultades en las que entraremos más en profundidad en la siguiente sección.

4. Estudio experimental

En esta sección se recoge el caso específico que hemos creado para comprobar la viabilidad de nuestra solución. Explicaremos qué datos hemos escogido para las pruebas, cómo se han configurado, qué métricas de evaluación usamos, qué pruebas vamos a realizar y por último analizaremos los resultados obtenidos.

4.1. Datos de entrenamiento y evaluación

Como no se tienen datos federados reales (por cuestiones obvias de privacidad), se busca simular un entorno en el que cada cliente tiene un conjuntos de datos con sus propias etiquetas no compartidas con los demás, buscando que cada uno tenga distintas tareas a entrenar. Para ello no solo vamos a separar los diferentes ejemplos por cada cliente sino que también tenemos que hacer una discriminación por etiquetas para que sean únicas entre cada uno de ellos.

Como base vamos a usar el conjunto de imágenes multi-etiqueta Corel-5k, que tiene 5000 imágenes de 50 categorías y un diccionario de 260 palabras o etiquetas [1]. A partir de él crearemos 4 conjuntos de datos con 10 etiquetas diferentes cada uno, ya que vamos a usar 4 clientes en nuestra federación. Para hacer la separación por etiquetas vamos a ordenar las 40 que más se repiten, creando cuatro grupos de 10 etiquetas de manera que el número de ejemplos de cada grupo sea similar. Las etiquetas se distribuyen en los conjuntos como aparece en la Tabla 4.1. Cada separación de datos tiene alrededor de 4400 ejemplos y unas 5000 etiquetas.

Como comentamos antes, la implementación de FedPer que estamos usando está implementada para clasificación multi-etiqueta. Debemos adaptar la arquitectura para poder implementar la clasificación multi-clase. Para ello hemos realizado modificaciones en la parte de la preparación de los datos, los clientes, el modelo y el tratamiento de métricas.

[1] `https://www.kaggle.com/datasets/parhamsalar/corel5k`

Conjunto 1		Conjunto 2		Conjunto 3		Conjunto 4	
Etiqueta	Número	Etiqueta	Número	Etiqueta	Número	Etiqueta	Número
water	2124	sky	1871	tree	1801	people	1414
buildings	870	mountain	652	flowers	565	grass	943
rocks	478	stone	444	snow	565	clouds	534
field	413	street	432	plane	423	bear	418
sand	387	birds	375	beach	372	boats	325
cars	285	leaf	284	plants	273	jet	313
polar	257	valley	255	house	267	bridge	261
ruins	257	garden	244	hills	244	Close-up	234
statue	223	horses	218	tracks	217	sun	212
wall	209	cat	203	ocean	201	ice	210

Cuadro 4.1: Distribución de etiquetas

Una vez tenemos los 4 grupos seleccionamos del dataset total los ejemplos correspondientes a las etiquetas de cada grupo. Por ejemplo si en nuestro grupo tenemos “agua” cogemos todos los elementos del conjunto de datos que estén etiquetados con “agua”, luego eliminamos de esos ejemplos todas las etiquetas que no correspondan a su grupo. Hacemos esto para los 4 subsets y así conseguimos separar las imágenes de manera que cada conjunto solo contenga etiquetas propias y que el número de ejemplos sea parecido, consiguiendo así simular el caso federado donde cada cliente solo posee información de sus etiquetas, que son distintas del resto de clientes.

Con los cuatro conjuntos creados realizamos las particiones entre conjuntos de entrenamiento y conjuntos de evaluación en una proporción de 80 % para el entrenamiento y 20 % para la evaluación.

Una vez hemos conseguido fabricar unos conjuntos de datos que nos permitan simular una situación real en la que tenemos conjuntos de datos distintos que quieren entrenar un mismo modelo lo siguiente es preparar el sistema que va a procesar esos datos.

4.2. Métricas de evaluación

A la hora de comprobar la bondad de nuestro modelo tenemos un problema añadido la salida comprende más de una etiqueta. Por ejemplo, si el resultado esperado tiene dos clases activas y el modelo solo ha predicho una de ellas, si comprobamos el valor exacto de todas las etiquetas marcaríamos la precisión como 0, sin embargo hay una que sí ha sido correcta y también se podría evaluar de forma parcialmente positiva. Podríamos comprobar etiqueta a etiqueta si tiene un valor correcto pero si

la mayoría de valores en las etiquetas son 0, un modelo que prediga siempre 0 podría tener una precisión muy alta y no funcionaría correctamente. Por eso debemos buscar métricas que tengan en cuenta los aciertos y los fallos de manera global.

Estas métricas son calculadas por cada etiqueta. En los casos en que necesitamos un valor único promedio, seguimos el enfoque *micro-averaged*; es decir, se cuenta el total de verdaderos positivos, falsos negativos y falsos positivos, y luego realiza el cálculo de la métrica.

4.2.1. Label ranking average precision

Dado que necesitamos una métrica de precisión para el entrenamiento, vamos a usar la métrica implementada en scikit learn *Label ranking average precision score*. Esta métrica ordena las predicciones según el valor de probabilidad asignado por el modelo y responde a la pregunta para cada etiqueta verdadera, ¿qué fracción de las etiquetas predichas con valor más alto son correctas? Está relacionada con la precisión, que veremos más adelante, pero se basa en el concepto de *ranking* en vez en la *precision* y el *recall*. Esta métrica será mayor si el modelo es capaz de dar una mayor probabilidad a las etiquetas verdaderas.

4.2.2. Matriz de confusión

Una matriz de confusión distribuye las predicciones en base a la salida esperada de la siguiente manera:

1. Verdaderos negativos (TN): Ausencia de clase predicha correctamente
2. Verdaderos positivos (TP): Clases predichas correctamente
3. Falsos positivos (FP): Clase predicha incorrectamente
4. Falsos negativos (FN): Ausencia de clase predicha incorrectamente

Distribuidas de la siguiente manera:

$$\begin{bmatrix} TN & FP \\ FN & TP \end{bmatrix}$$

Imaginemos que tenemos tres imágenes con las siguientes etiquetas, como se ve en la Tabla 4.2:

water	buildings	rocks	field	sand	cars	polar	ruins	statue	wall
1	0	1	0	0	0	0	0	0	0
0	1	0	0	0	1	0	0	0	0
1	0	1	0	0	0	0	0	0	0

Cuadro 4.2: Ejemplos

Y el modelo realiza las siguiente predicciones, como se ve en la Tabla 4.3:

water	buildings	rocks	field	sand	cars	polar	ruins	statue	wall
1	0	0	0	0	1	0	0	0	0
0	1	0	0	0	1	0	0	0	0
0	0	0	0	0	1	0	0	0	0

Cuadro 4.3: Predicciones

Las matrices de confusión para cada etiqueta serían

Water:

$$\begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}$$

Buildings:

$$\begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}$$

Rocks:

$$\begin{bmatrix} 1 & 0 \\ 2 & 0 \end{bmatrix}$$

Cars:

$$\begin{bmatrix} 0 & 2 \\ 0 & 1 \end{bmatrix}$$

La salida de nuestro modelo, como comentamos anteriormente, son *logits*, números entre menos infinito y más infinito, por lo que antes de poder crear la matriz de confusión debemos realizar la operación *sigmoid* para convertirlos en probabilidades (valores entre 0 y 1) y luego asignar un 0 si el valor es menor de 0,5 y 1 si el valor es mayor a 0,5. Una vez tenemos nuestra matriz de confusión para cada ejemplo del *batch* de evaluación podremos calcular el resto de las métricas.

Accuracy

La *accuracy* o exactitud es la proporción de ejemplos correctamente clasificados. Se define por la suma de todos los valores positivos y negativos predichos correctamente dividido entre el número de ejemplos en el conjunto de datos.

$$\uparrow Accuracy = \frac{TP + TN}{FP + FN + TP + TN}$$

Para la etiqueta *water* vemos que hay tres ejemplos en el conjunto de datos, la predicción del modelo es correcta en dos de los tres, por lo que la exactitud en este caso sería $2/3 = 0,66 = 66\,\%$

Precision

La *precision* o precisión es la proporción de predicciones correctas entre todas las predicciones. Se define por la proporción de verdaderos positivos entre todas las predicciones positivas.

$$\uparrow Precision = \frac{TP}{FP + TP}$$

En el mismo ejemplo de la etiqueta *water* los verdaderos positivos son 1 y el total de predicciones positivas es 2, la precisión para esta etiqueta sería $1/2 = 0{,}5 = 50\,\%$

Recall

Recall o sensibilidad es la proporción de ejemplos que han sido predichos como pertenecientes a su etiqueta. Es la proporción de verdaderos positivos con respecto a todos los ejemplos verdaderos (verdaderos positivos y verdaderos negativos).

$$\uparrow Recall = \frac{TP}{FN + TP}$$

Para *water* vemos que el número de etiquetas en los ejemplos es 2, y solo una de ellas ha sido clasificada correctamente, por lo que la sensibilidad se calcula como $1/2 = 0{,}5 = 50\,\%$

Specificity

La *specificity* o especificidad nos indica cuántos de los casos marcados como negativos son correctos. Se define como la proporción de negativos verdaderos entre todos los que deben ser negativos.

$$\uparrow Specificity = \frac{TN}{TN + FP}$$

En nuestro caso hay un negativo verdadero y ningún falso positivo porque lo que todos los negativos han sido predichos correctamente, la función es $1/1 = 1 = 100\,\%$

Fall out

El *fall out* es la tasa de falsos positivos. Se define como la proporción de falsos positivos entre todos los ejemplos que deben ser negativos.

$$\downarrow Fallout = \frac{FP}{FP + TN}$$

Para *water*, no existe ningún ejemplo de falsos positivos por lo que la fórmula queda $0/1 = 0 = 0\,\%$

Miss rate

El *miss rate* es la tasa de falsos negativos. Se define como la proporción de falsos negativos entre los ejemplos que deberían haber sido positivos. Nos dice cuántos de los ejemplos positivos han fallado en la predicción.

$$\downarrow Missrate = \frac{FN}{FN + TP}$$

En el ejemplo hay un falso negativo y un ejemplo marcado como negativo que debería ser positivos por lo que la fórmula queda $1/2 = 0,5 = 50\,\%$

4.2.3. F1 Score

El *F1 Score* para una clase es la media armónica ebtre la precisión y la sensibilidad. Se usa como medida general de la calidad de las predicciones del clasificador. Se suele elegir como métrica representativo porque une las dos medidas que miden las predicciones correctas *precision* y *recall*.

$$\uparrow F_1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

En nuestro ejemplo se calcula F1 como $0,25/1 = 0,25 = 25\,\%$

4.3. Configuración de los experimentos

Vamos a montar un sistema que nos permita comparar el rendimiento de un clasificador multi-etiqueta en un entorno federado y uno centralizado usando los mismos parámetros, para ver si existe mejora en la tarea al pertenecer a un grupo colaborativo de entrenamiento. Para el caso federado ejecutaremos una serie de rondas de servidor y recopilaremos las métricas para cada cliente. En el caso sin federar, para cada conjunto de datos se ejecutará el mismo número de rondas sin compartir información por tanto entre clientes, de esta manera habrán realizado ambos casos los mismos pasos de entrenamiento.

Repasaremos la ejecución para definir los parámetros específicos a nuestra implementación.

El programa inicializa los datos, el servidor y los cuatro clientes asignando un conjunto de dato de los cuatro a cada cliente. Tener cuatro clientes nos permite un número manejable de ciclos de entrenamiento para poder analizar los resultados. El Servidor inicializa la parte común del modelo usando la red ResNet34 y lo envía a cada uno de los clientes. Los clientes complementan el modelo con la ResNet34 del Servidor y la parte personalizada conformada por dos capas convolucionales y una capa linear de salida de dimensión 10. Cada cliente inicializa sus capas personalizadas.

Una vez inicializados el Servidor y los Clientes comienza el entrenamiento. Primero cada cliente ejecuta cuatro épocas de entrenamiento usando su conjunto de datos de entrenamiento. Para la función de pérdida se usa *BCEWithLogits* con los pesos adaptados a cada conjunto de datos, de esta forma las etiquetas que aparecen menos se les da más peso y las que aparecen más veces menos evitando así que el modelo solo aprenda a clasificar las etiquetas que más se repiten. Para la función de optimización se usa *SGS* (Descenso del Gradiente Estocástico). En cada

época se realiza un paso de entrenamiento con el conjunto de entrenamiento en lotes de 64 ejemplos cada vez. Cuando termina el entrenamiento el cliente separa la ResNet34 de las capas personalizadas y la devuelve actualizada al Servidor, éste recoge los modelos actualizados de cada cliente y usa FedAvg para realizar la agregación y obteniendo como resultado una nueva versión del modelo global que volverá a enviar a los clientes iniciando así otra nueva ronda de entrenamiento local. Antes de comenzar la siguiente ronda se ejecutan las funciones de evaluación para cada cliente donde, con los datos de evaluación, se ejecuta el modelo en lotes de 64 ejemplos. Para cada evaluación se calcula la matriz de confusión y las métricas derivadas y se guarda un registro de los resultados de cada cliente para esa ronda (por razones de evaluación y análisis de resultados posterior). Este proceso se repite durante 100 rondas. Podemos ver un resumen de la configuración en la Tabla 4.4

Rondas	100
Épocas locales	4
Clientes	4
Etiquetas por cliente	10
Lotes	64
Modelo compartido	ResNet34
Capas personalizadas	2 conv 1 linear
Función de pérdida	BCEWithLogits
Función de optimización	SGD

Cuadro 4.4: Configuración del experimento

4.4. Análisis de resultados

En primer lugar, vamos a analizar y comparar la evolución (en concreto, de la métrica F1) del modelo a lo largo de las distintas épocas de entrenamiento, tanto para el modelo federado, como para los modelos centralizados (donde cada cliente entrena únicamente con sus datos, sin colaborar con el resto). Al comparar la evolución para cada conjunto de datos obtenemos las Figuras 4.1 4.2 4.3 4.4.

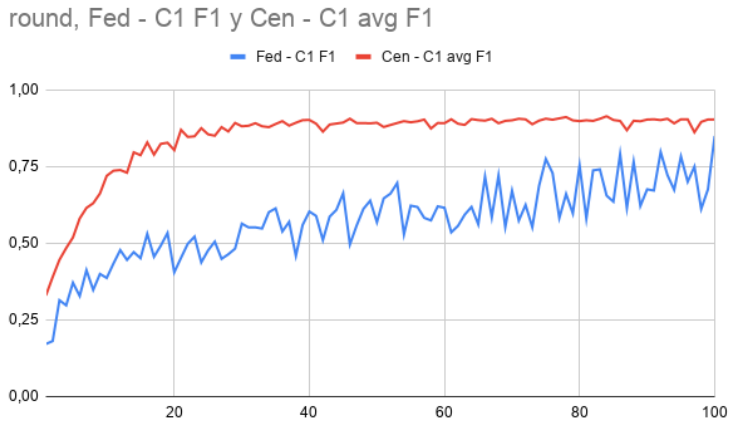


Figura 4.1: F1 Federado contra no federado para el Cliente 1

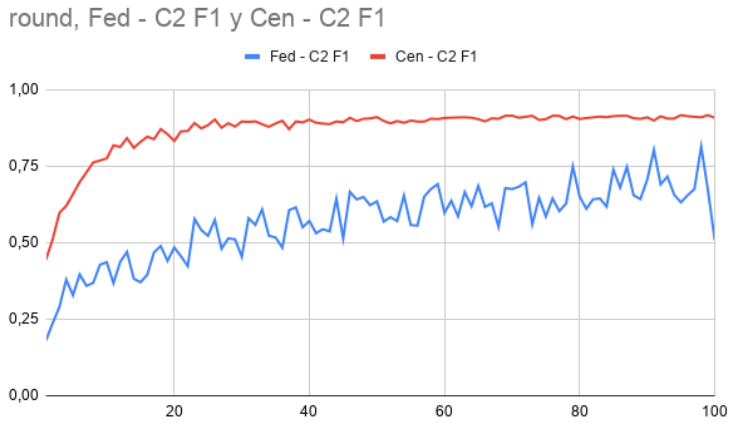


Figura 4.2: F1 Federado contra no federado para el Cliente 2

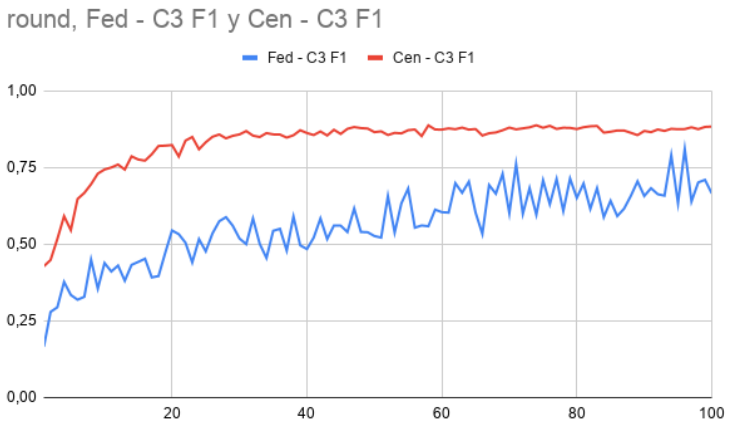


Figura 4.3: F1 Federado contra no federado para el Cliente 3

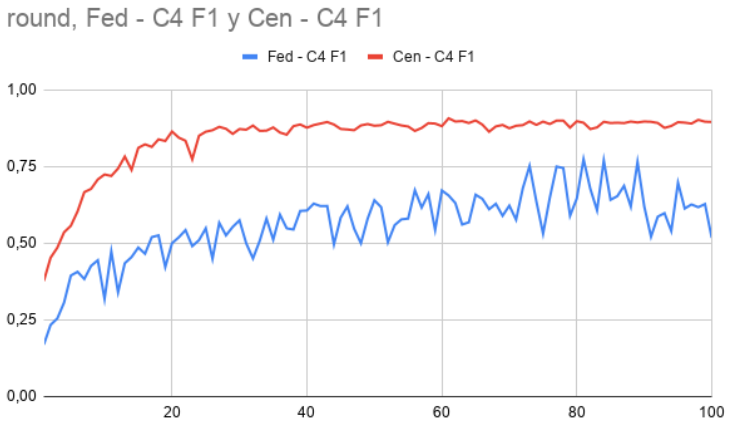


Figura 4.4: F1 Federado contra no federado para el Cliente 4

Podemos observar que en los cuatro ejemplos la evolución de la métrica F1 para el caso no federado tiene menor variación de una ronda a la siguiente mientras que en el caso federado vemos que se crean unos picos posiblemente debido al efecto de la agregación del servidor sobre el rendimiento del cliente.

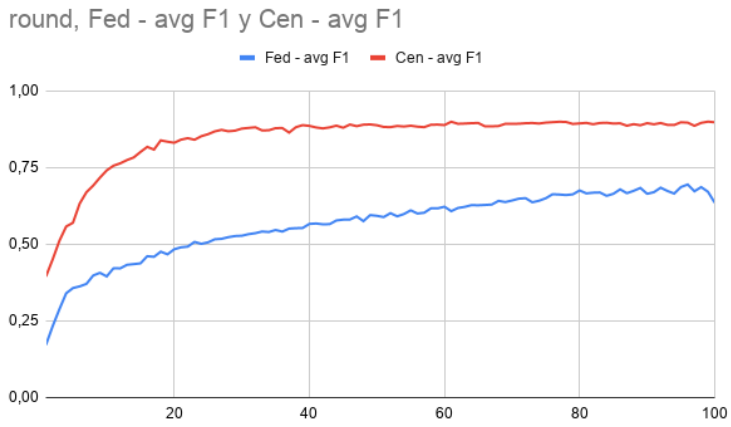


Figura 4.5: Promedio de F1 entre los cuatro clientes federados, respecto a la media de F1 en los casos centralizados

Si estudiamos la forma de las funciones F1 medias para los cuatro conjuntos de datos como vemos en la Figura 4.5 vemos de manera más clara la tendencia antes comentada y de forma más suavizada. Se observa claramente que el rendimiento del caso federado es menor al caso no federado, sin embargo se observa que el valor de F1 es ascendente acercándose al caso no federado.

A continuación, en las Tablas 4.5 4.8 4.9 4.11 se muestran las métricas derivadas de la matriz de confusión para cada etiqueta en la ronda 100. Mostramos tanto para el caso federado como para el no federado para cada conjunto de datos y para cada etiqueta el valor de F1, accuracy, precision, recall, specificity, fall out y miss rate. Hemos marcado en negrita los valores que mejoran en el caso federado con respecto a su contraparte en el caso sin federar.

Class	f1_score	accuracy	precision	recall	specificity	fall_out	miss_rate
water	0,9289	0,9353	0,9181	0,9407	0,9308	0,0692	0,0593
buildings	0,8546	0,9487	0,8555	0,8757	0,9656	0,0344	0,1243
rocks	**0,8033**	0,9688	**0,8171**	**0,8375**	**0,9816**	**0,0184**	**0,1625**
field	0,9256	0,9855	0,9278	0,9375	0,9912	0,0088	0,0625
sand	0,8686	0,981	0,9079	0,8734	0,9914	0,0086	0,1266
cars	**0,8492**	0,9911	0,925	**0,881**	0,9965	0,0035	**0,119**
polar	**0,8589**	0,9922	0,9	**0,9574**	0,9941	0,0059	**0,0426**
ruins	0,8564	**0,9866**	0,907	**0,8298**	0,9953	0,0047	**0,1702**
statue	**0,7254**	0,9922	0,878	0,9474	0,9942	0,0058	0,0526
wall	0,7349	0,9922	0,8837	0,95	0,9942	0,0058	0,05

Cuadro 4.5: Métricas para el cliente 1 centralizado en la ronda 100

Class	f1_score	accuracy	precision	recall	specificity	fall_out	miss_rate
water	0,8877	0,9016	0,8988	0,8806	0,9184	0,0812	0,119
buildings	0,8235	0,9352	0,819	0,8386	0,9576	0,042	0,161
rocks	0,8407	0,9688	0,8568	0,8386	0,9842	0,0168	0,161
field	0,8547	0,9716	0,903	0,8148	0,9898	0,0098	0,1848
sand	0,6821	0,9464	0,6104	0,84	0,9548	0,0448	0,1596
cars	0,8774	0,987	0,8176	0,9996	0,9856	0,014	0
polar	0,9110	0,9926	0,875	0,9996	0,9912	0,0084	0
ruins	0,8419	0,9856	0,8246	0,8456	0,9912	0,0084	0,154
statue	0,8259	0,9842	0,8638	0,826	0,9926	0,007	0,1736
wall	0,6469	0,966	0,6664	0,7504	0,9786	0,021	0,2506

Cuadro 4.6: Métricas para el cliente 1 federado en la ronda 100

En el las Tablas 4.5 y 4.6 observamos una mejoría en algunas métricas para las etiquetas *rocks*, *cars*, *polar* y *statue*, sin embargo en general los valores del resto de etiquetas empeoran. El modelo federado ha logrado superar en algunos casos al no federado pero en conjunto el rendimiento empeora.

Para el resto de conjuntos de datos (Tablas 4.7, 4.9, 4.11, 4.8, 4.10, 4.12), las métricas para todas las etiquetas son peores.

Class	f1_score	accuracy	precision	recall	specificity	fall_out	miss_rate
sky	0,9413	0,9483	0,9309	0,9537	0,9441	0,0559	0,0463
mountain	0,8538	0,9555	0,877	0,8295	0,9787	0,0213	0,1705
stone	0,9226	0,9856	0,9302	0,9302	0,992	0,008	0,0698
street	0,8494	0,9784	0,8	0,9333	0,9819	0,0181	0,0667
birds	0,8541	0,9784	0,8182	0,9403	0,9817	0,0183	0,0597
leaf	0,9403	0,9916	0,9636	0,9138	0,9974	0,0026	0,0862
valley	0,8269	0,9796	0,8182	0,8654	0,9872	0,0128	0,1346
garden	0,8714	0,9928	0,9556	0,9149	0,9975	0,0025	0,0851
horses	0,8206	0,9868	0,9091	0,8511	0,9949	0,0051	0,1489
cat	0,7960	0,9916	0,8788	0,9062	0,995	0,005	0,0938

Cuadro 4.7: Métricas para el cliente 2 centralizado en la ronda 100

Class	f1_score	accuracy	precision	recall	specificity	fall_out	miss_rate
sky	0,6515	0,715	0,6643	0,6461	0,7644	0,2353	0,3536
mountain	0,2845	0,754	0,273	0,3107	0,8398	0,1612	0,689
stone	0,3589	0,8463	0,3328	0,4381	0,8944	0,1053	0,5616
street	0,4375	0,884	0,3861	0,5343	0,9178	0,0819	0,4654
birds	0,5940	0,9178	0,533	0,7605	0,9334	0,0663	0,2405
leaf	0,7541	0,962	0,7124	0,8255	0,9724	0,0273	0,1742
valley	0,3675	0,9334	0,3393	0,5135	0,9529	0,0468	0,4862
garden	0,3195	0,9009	0,2756	0,3731	0,936	0,0637	0,6279
horses	0,4651	0,9373	0,4563	0,5538	0,9607	0,039	0,4472
cat	0,4271	0,9438	0,4173	0,5122	0,9646	0,0351	0,4875

Cuadro 4.8: Métricas para el cliente 2 federado en la ronda 100

Class	f1_score	accuracy	precision	recall	specificity	fall_out	miss_rate
tree	0,8901	0,9062	0,882	0,8971	0,9129	0,0871	0,1029
flowers	0,8629	0,9663	0,8981	0,8509	0,9847	0,0153	0,1491
snow	0,9262	0,9808	0,8952	0,9737	0,9819	0,0181	0,0263
plane	0,9147	0,988	0,9467	0,9221	0,9947	0,0053	0,0779
beach	0,8806	0,9832	0,9452	0,8734	0,9947	0,0053	0,1266
plants	0,7937	0,982	0,878	0,7826	0,9936	0,0064	0,2174
house	0,7938	0,9724	0,8182	0,7759	0,9871	0,0129	0,2241
hills	0,7401	0,9748	0,8163	0,7692	0,9885	0,0115	0,2308
tracks	0,6266	0,9844	0,7568	0,875	0,9888	0,0112	0,125
ocean	0,7890	0,994	0,9167	0,9429	0,9962	0,0038	0,0571

Cuadro 4.9: Métricas para el cliente 3 centralizado en la ronda 100

Class	f1_score	accuracy	precision	recall	specificity	fall_out	miss_rate
tree	0,7518	0,7969	0,7891	0,7254	0,8515	0,1482	0,2756
flowers	0,6500	0,8996	0,5941	0,7449	0,923	0,078	0,2548
snow	0,6538	0,91	0,6175	0,6955	0,9399	0,0598	0,3042
plane	0,4960	0,9022	0,4797	0,598	0,9334	0,0663	0,403
beach	0,7048	0,9464	0,6409	0,8307	0,9568	0,0429	0,169
plants	0,5417	0,9087	0,4238	0,7969	0,9178	0,0832	0,2028
house	0,5571	0,9334	0,4212	0,8333	0,9386	0,0611	0,1664
hills	0,5131	0,9373	0,4602	0,6175	0,9568	0,0429	0,3835
tracks	0,7122	0,9698	0,7202	0,7657	0,9828	0,0182	0,234
ocean	0,6552	0,9542	0,4927	0,8918	0,9568	0,0429	0,1079

Cuadro 4.10: Métricas para el cliente 3 federado en la ronda 100

Class	f1_score	accuracy	precision	recall	specificity	fall_out	miss_rate
people	0,9084	0,9423	0,9044	0,9179	0,9539	0,0461	0,0821
grass	0,8966	0,9555	0,8989	0,8939	0,9724	0,0276	0,1061
clouds	0,9128	0,9796	0,9115	0,9364	0,9861	0,0139	0,0636
bear	0,8680	0,9796	0,8442	0,9286	0,9843	0,0157	0,0714
boats	0,9094	0,9868	0,9508	0,8788	0,9961	0,0039	0,1212
jet	0,9062	0,9892	0,875	0,9608	0,991	0,009	0,0392
bridge	0,7822	0,9772	0,8409	0,7551	0,9911	0,0089	0,2449
close-up	0,8200	0,988	0,8605	0,9024	0,9924	0,0076	0,0976
sun	0,9410	0,994	0,9216	0,9792	0,9949	0,0051	0,0208
ice	0,6488	0,976	0,7073	0,7838	0,9849	0,0151	0,2162

Cuadro 4.11: Métricas para el cliente 4 centralizado en la ronda 100

Class	f1_score	accuracy	precision	recall	specificity	fall_out	miss_rate
people	0,5651	0,6851	0,5018	0,6617	0,6955	0,3042	0,338
grass	0,4838	0,8047	0,5239	0,4589	0,8931	0,1079	0,5408
clouds	0,4629	0,8671	0,4758	0,4719	0,9243	0,0754	0,5278
bear	0,4964	0,8814	0,429	0,6214	0,9087	0,091	0,3783
boats	0,5314	0,9061	0,4732	0,6162	0,9347	0,0663	0,3835
jet	0,4708	0,9165	0,5356	0,4056	0,9659	0,0338	0,5941
bridge	0,3431	0,8918	0,2977	0,4459	0,9243	0,0754	0,5538
close-up	0,4792	0,9464	0,4654	0,4758	0,9711	0,0286	0,5239
sun	0,4285	0,9542	0,455	0,5876	0,9698	0,0299	0,4121
ice	0,4944	0,9477	0,4563	0,6669	0,9607	0,039	0,3328

Cuadro 4.12: Métricas para el cliente 4 federado en la ronda 100

Client	f1_score	accuracy	precision	recall	specificity	fall_out	miss_rate
Client 1	0,84058	0,97736	0,89201	0,90304	0,98349	0,01651	0,09696
Client 2	0,86764	0,97886	0,88816	0,90384	0,98504	0,01496	0,09616
Client 3	0,82177	0,97321	0,87532	0,86628	0,98231	0,01769	0,13372
Client 4	0,85934	0,97682	0,87151	0,89369	0,98471	0,01529	0,10631
Promedio	0,8473325	0,9765625	0,88175	0,8917125	0,9838875	0,0161125	0,1082875

Cuadro 4.13: Métricas promedio en la ronda 100 para el caso centralizado

Client	f1_score	accuracy	precision	recall	specificity	fall_out	miss_rate
Client 1	0,81918	0,9639	0,81354	0,86338	0,9744	0,02534	0,13636
Client 2	0,46597	0,87945	0,43901	0,54678	0,91364	0,08619	0,45331
Client 3	0,62357	0,91585	0,56394	0,74997	0,93574	0,06435	0,25012
Client 4	0,47556	0,8801	0,46137	0,54119	0,91481	0,08515	0,45851
Promedio	0,59607	0,909825	0,569465	0,67533	0,9346475	0,0652575	0,324575

Cuadro 4.14: Métricas promedio en la ronda 100 para el caso federado

Al realizar la media de todas las métricas para cada cliente formamos las Tablas 4.13 y 4.14 que nos dan una visión del rendimiento de cada caso. Observamos unos mejores resultados para el cliente 1, sin embargo empeora para el resto re clientes en la ronda 100.

5. Conclusiones y trabajo futuro

En esta sección comentaremos las conclusiones a las que llegamos a través de ese análisis y propondremos el trabajo futuro en esta línea.

5.1. Conclusiones

En este trabajo hemos realizado un análisis del estado del arte en el ámbito del aprendizaje federado y en el de la clasificación de imágenes multi-etiqueta poniendo especial atención en el estudio de la heterogeneidad dentro de estos sistemas. Se ha propuesto un modelo para aprendizaje federado multi-etiqueta en el que los clientes tiene diferentes etiquetas usando la aproximación de crear un modelo mixto con capas personalizadas en los clientes y capas compartidas con el servidor. Se ha realizado un estudio experimental con un conjunto de datos multi-etiqueta para comparar el rendimiento con respecto a otro sistema sin federar que tiene la misma configuración. Por último, se han definido una serie de métricas que nos permite evaluar el rendimiento de nuestro experimento.

Nuestra hipótesis inicial era que para la tarea de clasificación de imágenes multi-etiqueta donde varios clientes deben entrenar con un conjunto de datos con etiquetas diferentes, el pertenecer a un entorno federado podría mejorar el rendimiento ya que los distintos clientes necesitan de un aprendizaje común (reconocimiento de bordes, texturas, sombras, etcétera...) que se delega a la parte compartida del modelo mientras la tarea de clasificación en sí permanece en las capas personalizadas de cada cliente. Aplicar un algoritmo como FedPer nos debería permitir atacar el problema del desbalance de etiquetas en los clientes de manera satisfactoria. Al analizar los resultados del experimento observamos que existen dificultades en el entrenamiento del modelo derivados probablemente de la acción de agregación por parte del servidor que afecta negativamente a la convergencia en el cliente.

A pesar de los resultados negativos, vemos que hay una tendencia ascendente en la mejora del rendimiento conforme avanzan las rondas de servidor por lo que

deducimos que aún existe margen de mejora para este experimento, a continuación se enumeran varias opciones:

1. **Algoritmo de agregación** Como hemos comentado anteriormente la diferencia principal entre los dos casos que hemos comparado (Federado vs no federado) es que realizamos la evaluación de cada cliente después de realizar la agregación en el servidor de sus respectivos modelos usando FedAvg. Existen algoritmos que estudian cómo mitigar los efectos de los datos heterogéneos en el momento de la agregación como los algoritmos SCAFFOLD [23] y FedProx [24]. El uso de algoritmos diferentes podrían mejorar la convergencia de los modelos locales en cada cliente.

2. **Épocas locales** Teorizamos que un mayor número de épocas locales afecta a la variación del modelo compartido en mayor medida, minimizando el número de épocas podríamos hacer que la variación de los pesos fuese menor por lo que el impacto que tuviese el entrenamiento en un cliente en otro también disminuiría.

3. **Número de rondas federadas** En todos los clientes observamos una mejora conforme avanzan las rondas federadas. Añadiendo más rondas podríamos llegar a un punto en el que los resultados igualasen o mejorasen al caso no federado que se estabiliza en torno al 0.85 en la métrica F1. Se podrían multiplicar el número de pasos de entrenamiento para terminar de evaluar las limitaciones de este algoritmo.

4. **Conjunto de datos** En nuestro estudio pretendemos crear un sistema en el que cada cliente entrene etiquetas distintas, sin embargo, en el conjunto de datos que hemos usado para realizar el experimento también existe un importante desbalance en el número de ocurrencias de cada etiqueta. Eligiendo un conjunto de imágenes multi-etiqueta que no presentase esta característica se obtendrían mejores resultados y facilitaría el análisis evitando la dificultad añadida que nos aporta este desbalance.

5.2. Trabajo futuro

Los datos experimentales obtenidos nos dejan ver que aunque el rendimiento sea peor dentro de un entorno federado que en uno centralizado, para algunas etiquetas el resultado ha sido mejor, por lo que se intuye que hay margen de mejora y aún hay camino que recorrer en esta dirección. Como hemos comentado en el punto anterior tenemos varias opciones para mejorar nuestro modelo. Un sistema que permita a un cliente entrenar una tarea de clasificación en cooperación con otros nodos tendría muchas aplicaciones en el mundo real en distintos campos donde es un requisito la privacidad de los datos como puede ser el procesamiento

de imágenes médicas, video-vigilancia u otros ámbitos donde se pueda aplicar la clasificación de imágenes de manera que los costes del entrenamiento puedan ser distribuidos entre los distintos actores.

Una vez asentada la base de nuestro modelo, como podemos observar en las conclusiones, tenemos como tarea pendiente mejorar el rendimiento poniendo el foco en la agregación del servidor, los parámetros de configuración o los datos de entrenamiento.

Y una vez solventado el problema del rendimiento podemos proponer otro experimento como el de introducir un número de etiquetas distintas para cada cliente. Al delegar la parte de la salida del modelo a las capas personalizadas no debería afectar al entrenamiento global, esto nos daría más flexibilidad a la hora de introducir nuevos clientes con diferentes necesidades o formatos de clasificación.

Por último proponemos la introducción de un cliente sin entrenar en un sistema federado ya entrenado. De esta manera el cliente podría hacer uso de la parte del modelo compartido con el servidor que estaría pre-entrenada y debería de mejorar el entrenamiento de manera más rápida que si entrenase solo ya que solo tendría que ajustar las capas personalizadas en lugar del modelo completo.

Bibliografía

[1] Jose M. Moyano. Multi-label classification models for heterogeneous data: an ensemble-based approach, 2020.

[2] Qiang Yang, Yang Liu, Yong Cheng, Yan Kang, Tianjian Chen, and Han Yu. *Federated Learning*. Morgan & Claypool publishers, 2019.

[3] M. Victoria Luzón, Nuria Rodríguez-Barroso, Alberto Argente-Garrido, Daniel Jiménez-López, Jose M. Moyano, Javier Del Ser, Weiping Ding, and Francisco Herrera. A tutorial on federated learning from theory to practice: Foundations, software frameworks, exemplary use cases, and selected trends. *IEEE/CAA Journal of Automatica Sinica*, 11(4), 2024.

[4] H. Brendan McMahan, Eider Moore, Daniel Ramage, Seth Hampson, and Blaise Agüera y Arcas. Communication-efficient learning of deep networks from decentralized data. 2023.

[5] Mang Ye, Xiuwen Fang, Bo Du, Pong C. Yuen, and Dacheng Tao. Heterogeneous federated learning: State-of-the-art and research challenges. *ACM Comput. Surv.*, 56(3), October 2023.

[6] Yue Zhao, Meng Li, Liangzhen Lai, Naveen Suda, Damon Civin, and Vikas Chandra. Federated learning with non-iid data. 2018.

[7] Marcos F. Criado, Fernando E. Casado, Roberto Iglesias, Carlos V. Regueiro, and Senén Barro. Non-iid data and continual learning processes in federated learning: A long road ahead. 2021.

[8] Zhaobin Sun, Nannan Wu, Junjie Shi, Li Yu, Xin Yang, Kwang-Ting Cheng, and Zengqiang Yan. Fedmlp: Federated multi-label medical image classification under task heterogeneity. 2024.

[9] Manoj Ghuhan Arivazhagan, Vinay Aggarwal, Aaditya Kumar Singh, and Sunav Choudhary. Federated learning with personalization layers. 2019.

[10] Xuelin Zhu, Xiu-Shen Wei, Jiawei Ge, Shuai Xu, and Bing Wang. Rethinking multi-label image classification with deep learning: Taxonomy, challenge, and outlook. 2026.

[11] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. 2015.

[12] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. 2021.

[13] Zhao-Min Chen, Xiu-Shen Wei, Peng Wang, and Yanwen Guo. Multi-label image recognition with graph convolutional networks. 2019.

[14] Emanuel Ben-Baruch, Tal Ridnik, Nadav Zamir, Asaf Noy, Itamar Friedman, Matan Protter, and Lihi Zelnik-Manor. Asymmetric loss for multi-label classification. 2021.

[15] Shilong Liu, Lei Zhang, Xiao Yang, Hang Su, and Jun Zhu. Query2label: A simple transformer way to multi-label classification. 2021.

[16] Xuelin Zhu, Jian Liu, Weijia Liu, Jiawei Ge, Bo Liu, and Jiuxin Cao. Scene-aware label graph learning for multi-label image classification. pages 1473–1482, 2023.

[17] Xuelin Zhu, Jianshu Li, Jiuxin Cao, Dongqi Tang, Jian Liu, and Bo Liu. Semantic-guided representation enhancement for multi-label image classification. *IEEE Transactions on Circuits and Systems for Video Technology*, 34(10):10036–10049, 2024.

[18] Ming-Kun Xie, Jia-Hao Xiao, Pei Peng, Gang Niu, Masashi Sugiyama, and Sheng-Jun Huang. Counterfactual reasoning for multi-label image classification via patching-based training. 2024.

[19] Barış Büyüktaş, Kenneth Weitzel, Sebastian Völkers, Felix Zailskas, and Begüm Demir. Transformer-based federated learning for multi-label remote sensing image classification. 2024.

[20] Alessia Celeghin, Alessio Borriero, Davide Orsenigo, Matteo Diano, Carlos Andrés Méndez Guerrero, Alan Perotti, Giovanni Petri, and Marco Tamietto. Convolutional neural networks for vision neuroscience: significance, developments, and outstanding issues. *Frontiers in Computational Neuroscience*, Volume 17 - 2023, 2023.

[21] David Silver, Aja Huang, Christopher Maddison, Arthur Guez, Laurent Sifre, George Driessche, Julian Schrittwieser, Ioannis Antonoglou, Veda Panneershelvam, Marc Lanctot, Sander Dieleman, Dominik Grewe, John Nham, Nal Kalchbrenner, Ilya Sutskever, Timothy Lillicrap, Madeleine Leach, Koray Kavukcuoglu, Thore Graepel, and Demis Hassabis. Mastering the game of go with deep neural networks and tree search. *Nature*, 529:484–489, 01 2016.

[22] Kazuharu Furutani and Satomi Kita. Alphafold: a revolutionary ai-based protein structure prediction system and its applications in drug discovery research. *Folia Pharmacologica Japonica*, 160:302–304, 07 2025.

[23] Sai Praneeth Karimireddy, Satyen Kale, Mehryar Mohri, Sashank J. Reddi, Sebastian U. Stich, and Ananda Theertha Suresh. Scaffold: Stochastic controlled averaging for federated learning, 2021.

[24] Tian Li, Anit Kumar Sahu, Manzil Zaheer, Maziar Sanjabi, Ameet Talwalkar, and Virginia Smith. Federated optimization in heterogeneous networks, 2020.