



Trabajo Fin de Máster

Máster Universitario en Lógica,
Computación e Inteligencia Artificial

Departamento de Ciencias de la Computación e Inteligencia Artificial

Clasificación de imágenes multi-etiqueta en entornos federados

Autor/a:
D. Manuel Mateos Gutiérrez

Tutor:
Dr. Jose María Moyano Murillo

Sevilla, XX de XXXX de 20XX

Índice general

Índice de figuras **V**

Índice de tablas **VII**

1. Introducción **1**

2. Estado del arte **5**

2.1. Aprendizaje Federado 5

2.1.1. Aprendizaje federado heterogéneo 7

2.2. Clasificación multi-etiqueta 8

2.2.1. Descripción formal del MLC 9

2.2.2. Eligiendo modelo para clasificación multi-etiqueta 10

3. Federación con capas personalizadas y salidas heterogéneas (FedPerH) **11**

3.1. Datos de entrenamiento 11

3.2. Arquitectura de la solución 12

3.3. Métricas 12

4. Estudio experimental **13**

4.1. Configuración de los experimentos 13

4.2. Análisis de resultados 14

5. Conclusiones y trabajo futuro **15**

5.1. Conclusiones 15

5.2. Trabajo futuro 16

Bibliografía **17**

Índice de figuras

2.1. Entrenamiento federado cliente-servidor 6

2.2. Clasificación binaria y multi-clase 8

2.3. Clasificación multi-etiqueta 9

2.4. Ejemplo de conjunto de datos multi-etiqueta obtenido de [1] 9

Índice de tablas

1. Introducción

Vivimos una época de auge en el campo de la Inteligencia Artificial provocado por la llegada de nuevas tecnologías en modelos de lenguaje y sistemas generativos que han creado un aumento en la demanda y la inversión, lo que ha ocasionado que se desarrollen aún más estas tecnologías, se haya normalizado su uso y se estén integrando en muchos y variados ámbitos tanto cotidianos (agentes de voz y de texto, asistentes, buscadores...) como en los negocios (asistentes a la programación, automatizaciones, sistemas integrados en medicina e investigación, logística, hostelería...).

Este florecimiento ha traído consigo también nuevos desafíos tanto en arquitectura como en regulaciones. Que cada vez haya más dispositivos recolectando y produciendo datos necesarios para entrenar modelos hace que estos sistemas tengan que adaptarse para ser más flexibles y poder dar cobertura a diferentes tipos de topologías, por ejemplo, varios dispositivos móviles pueden colaborar para entrenar una red teniendo diferentes especificaciones. Asimismo la compartición de datos personales e información sensible trae consigo la necesidad de crear sistemas más seguros, por ejemplo una persona que esté entrenando un modelo con su geolocalización pero sin tener que compartir su posición con una empresa externa. Este tipo de problemas son el germen para el desarrollo de sistemas de aprendizaje federados [2].

La idea detrás de esta arquitectura es que varios clientes entrenen modelos locales y compartan los parámetros (por ejemplo, los pesos de la red) con un servidor de manera que todos cooperan en el entrenamiento conjunto de la red mientras que los datos nunca abandonan los clientes. Podemos imaginar un entorno en el que los clientes tienen datos sensibles (datos en un dispositivo personal o de pacientes en un centro sanitario) que no se desea compartir con una empresa externa o que no pueden salir de una determinada zona como por ejemplo datos de empresas de la Unión Europea que no se pueden compartir con servidores fuera de ella. A parte de la privacidad, otro beneficio es que los recursos requeridos para los entrenamientos locales son menores comparados con una estructura centralizada, de manera que el resultado de la cooperación de muchos clientes es más eficiente

que si trabajasen de manera aislada con esos mismos recursos. También es importante mencionar que de esta forma se permite de manera más fácil la integración de nuevos clientes (dispositivos, empresas, entidades públicas...) con sistemas ya establecidos.

Como caso de uso podemos plantear un entorno en el que varios centros médicos de diferentes disciplinas quieren hacer uso de un sistema de procesado de imágenes médicas sin que estas abandonen los centros. El coste de que cada centro entrene su propio modelo es alto y requeriría un gran número de datos de entrenamiento. Para que todos los centros pudieran colaborar en entrenar un mismo modelo tendrían que agregar las imágenes médicas en un mismo servidor y esto crearía problemas de privacidad y políticas de tratamiento de datos. Un sistema federado puede solucionar estos problemas ya que los datos no abandonan los clientes y al participar todos ellos en el entrenamiento común el resultado que obtienen es mayor que el aporte que hacen al entrenamiento por separado, por lo que los recursos son usados de manera más eficiente.

Sin embargo aún tendríamos un problema y es el de la especialización de cada cliente, en el supuesto actual todos ellos deberían realizar la misma tarea pero podría haber casos en los que las tareas específicas sean diferentes para cada uno, aun compartiendo características comunes en el aprendizaje. Por ejemplo, varios clientes quieren realizar clasificación de imágenes, pero cada uno tiene fotos de distinta tipología o quieren detectar diferentes conjuntos de objetos. Mientras que la tarea es común en todos, las clases o etiquetas a predecir son específicas de cada cliente.

Además de todos sus beneficios aún existen varios desafíos en el campo del aprendizaje federado. La bondad de los modelos federados está probada para datos homogéneos, pero cuando los datos son consistentes en etiquetas, características o cantidad es más fácil que los clientes al entrenarse lleguen a un máximo global. Sin embargo si hay desequilibrios en estas categorías es más fácil que lleguen a un máximo local, lo que dificulta la agregación de los pesos de las distintas redes de los clientes en el servidor.

En nuestro caso particular analizaremos la viabilidad de implementar un modelo de clasificación multi-etiqueta (donde cada ejemplo puede categorizarse en más de una clase o etiqueta al mismo tiempo) con datos heterogéneos dentro de un sistema federado. La idea es que cada cliente sea usado para una tarea diferente entrenando solo un subconjunto de etiquetas y se pueda beneficiar del aporte del resto de clientes.

El resto de la memoria se organiza del siguiente modo:

2. Estado del arte. En este capítulo se analizarán qué sistemas existen que implementen clasificación multi-etiqueta en entornos federados o qué estudios se

acercan. También se definirá la base da la que partiremos para nuestra implementación.

3. Propuesta. Se describen los sistemas desarrollados en este trabajo.

4. Estudio Experimental. Se presentan los resultados de los experimentos realizados.

5. Conclusiones y Trabajo Futuro. Se plantean las conclusiones y futuras ampliaciones del sistema y líneas de trabajo futuro en este campo.

2. Estado del arte

En esta sección explicaremos los elementos necesarios para la resolución del problema propuesto. Haremos una explicación en profundidad de los sistemas de aprendizaje federados y de la clasificación multi-etiqueta.

2.1. Aprendizaje Federado

En aprendizaje automático clásico tenemos un modelo que entrenamos con una serie de datos para que realice una tarea que puede ser reconocer objetos en una imagen, controlar la reacción de un sistema ante una situación o jugar a un juego. En la práctica estos datos no se generan en la máquina dónde entrenamos al modelo sino que pueden venir de un dispositivo móvil, unos sensores o un micrófono. Estos datos también pueden venir no de una única fuente sino de varios lugares que recopilen información para realizar una tarea en conjunto. La aproximación más común ante esta estructura de datos es unir todas las fuentes en un lugar centralizado y tratarlas para crear un único conjunto de datos y usarlo para realizar el entrenamiento de nuestro modelo.

Este enfoque no puede usarse en todos los casos, por ejemplo cuando los datos no pueden compartirse con el servidor central debido a regulaciones, preferencias de privacidad o simplemente que el volumen de datos es tan grande que el servidor no es capaz de procesarlos todos entre muchos otros ejemplos.

Frente a estos problemas nace el paradigma de aprendizaje federado [2] el cuál invierte esta estructura de manera que lleva el entrenamiento a los datos. Esto nos permite aplicar el campo de aplicación de los sistemas de aprendizaje automático a lugares donde antes era difícil o imposible debido a la naturaleza de los datos como detección de fraude financiero haciendo que varias entidades bancarias cooperen en el aprendizaje o mejorar modelos médicos agregando el entrenamiento de diferentes sistemas sanitarios sin que las normas de privacidad se vean comprometidas.

Hay varias aproximaciones como la arquitectura *peer to peer* donde todos los nodos comparten entre ellos el resultado del entrenamiento de los demás. Nosotros nos centraremos en explicar el aprendizaje federado en arquitectura cliente-servidor. Con este método primero se inicializa el modelo global con pesos aleatorios y se envía a todos los clientes, de esta manera nos aseguramos de que todos los clientes partan de los mismos parámetros. Luego cada cliente entrena su modelo local, que es una copia del modelo global con sus datos locales. Este entrenamiento no se realiza hasta la convergencia del modelo, sino solo realiza unos pocos pasos de entrenamiento. Una vez actualizado el modelo local de cada cliente estos envían la actualización al servidor ya sean los pesos o los gradientes. El servidor recibe una versión diferente del modelo inicial por cada cliente que ha participado en la ronda de entrenamiento. En este punto recordamos que el objetivo es que los clientes colaboren con sus entrenamientos parciales a actualizar un modelo global, para ello el servidor realiza una operación de unificación de todas las versiones del modelo que le han mandado mediante un proceso que llamamos agregación. El método más básico se conoce como *Federated Averaging* [3] abreviado como *FedAvg*. Este proceso realiza una media ponderada sobre los pesos de los diferentes modelos en base al número de ejemplos que han usado en el entrenamiento para asegurarse de que cada ejemplo que ha participado tiene la misma influencia. Una vez finalizada la agregación el servidor envía el nuevo modelo a cada uno de los clientes. Este proceso se vuelve a ejecutar en bucle hasta que los modelos locales alcanzan la convergencia o un número de rondas prefijado. Este proceso está ilustrado en la figura 2.1.

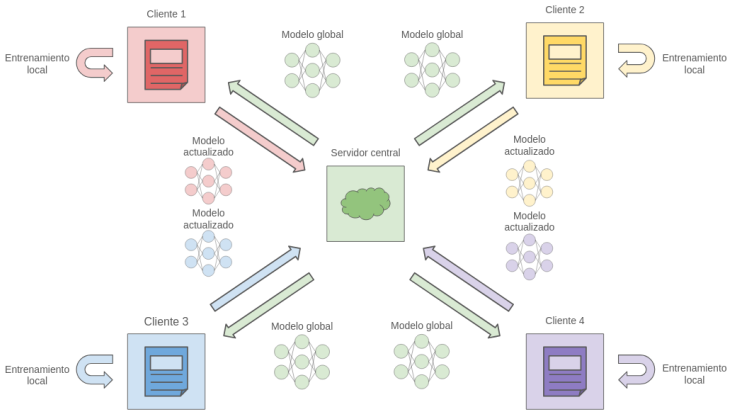


Figura 2.1: Entrenamiento federado cliente-servidor

2.1.1. Aprendizaje federado heterogéneo

En [4] se realiza una clasificación de los problemas presentes en las diferentes arquitecturas de modelos federados según si la heterogeneidad es estadística, en el modelo, en las comunicaciones o en los dispositivos. Si hablamos de la heterogeneidad estadística estamos hablando de los datos y el principal problema es que no sean independientes e identicamente distribuídos (no-IID) lo que hace que el aprendizaje se reduzca considerablemente [5] [6]. Ahondando más en esta categorización pueden tener desbalance de etiquetas, desbalance de características, desbalance de calidad y desbalance de cantidad. Artículos como [7] hablan de este problema en datos médicos y atacan el problema centrándose en la normalización de los datos.

El estudio también evalúa otros tipos de heterogeneidad en la comunicación, los dispositivos y los modelos y propone diferentes soluciones para mitigar estos problemas. El caso que nos compete tiene desbalance en etiquetas ya que como hemos comentado antes cada cliente va a entrenar una tarea distinta, por lo que los datos de cada uno solo tendrán un subconjunto de las etiquetas y también desbalance en los modelos ya que cada cliente va a tener un número de etiquetas diferente por lo que la salida de la red local no será consistente entre todo el sistema. En cuanto al desbalance en el modelo se proponen varias soluciones, una de ellas es la compartición de arquitectura, que consiste en compartir parte del modelo y hacer un entrenamiento personalizado, este método es capaz de solucionar tanto la heterogeneidad estadística como la de modelo y de dispositivo al mismo tiempo [8].

Los métodos a nivel de datos pueden resolver el problema asociado a las grandes diferencias en la distribución de los datos y acelerar la convergencia reduciendo heterogeneidad estadística entre ellos. Por el contrario, los métodos a nivel de modelo buscan aprender un modelo local para cada cliente que se adapte a su distribución de datos privada, esta solución es la que queremos estudiar en este trabajo.

2.2. Clasificación multi-etiqueta

Una de las tareas más extendidas en el ámbito del aprendizaje automático es la de la clasificación ya sea de textos, imágenes o cualquier otro tipo de conjunto de información. Consiste en crear un modelo en base a las características del conjunto de datos que vayamos a procesar para que realice una predicción sobre las clases asignadas a esos datos. Los ejemplos más comunes son la clasificación binaria y la clasificación multi-clase 2.2. En la clasificación binaria asignamos un valor binario a los datos de entrada, por ejemplo un sistema que detecte si un correo es spam o no. La clasificación multi-clase define una serie de elementos de los cuales se debe elegir el que sea más probable que sea relacionado con los datos que estamos evaluando, por ejemplo detectar qué tipo de animal aparece en una foto.



Figura 2.2: Clasificación binaria y multi-clase

En el mundo real existen muchos escenarios donde se requiere una clasificación múltiple en la misma tarea, por ejemplo detectar diferentes patologías en una imagen médica, añadir distintas categorías o temas a un texto, detectar diferentes objetos en un vídeo en tiempo real etcétera. En situaciones donde un mismo conjunto de datos pueden clasificarse con más de una clase como en la figura 2.3, donde aparecen dos animales diferentes, la clasificación multi-clase provocaría una pérdida de información. Debido a esto la clasificación multi-etiqueta es un campo que se ha desarrollado mucho en los últimos años.



Figura 2.3: Clasificación multi-etiqueta

2.2.1. Descripción formal del MLC

Siendo $\mathcal{D}$ un dataset multi-etiquetas compuesto por un conjunto de $\Updownarrow$ instancias, y definido como $\mathcal{D} = \{(x_i, Y_i)|1 \leq i \leq m\}$. Siendo $\mathcal{X} = X_1 \times \cdots \times X_d$ el espacio de entrada de dimensión d, e $\mathcal{Y} = \{\lambda_1, \lambda_2, \ldots, \lambda_q\}$ el espacio compuesto por $q > 1$ etiquetas. Cada instancia multi-etiqueta está compuesta por un vector de entrada xi y un conjunto de etiquetas relevantes asociadas a él $Y_i \subseteq Y$. Tener en cuenta que cada Y diferente también recibe el nombre de conjunto de etiquetas. En la figura 2.4, podemos ver un ejemplo de un conjunto de datos multi-etiqueta. Como podemos observar cada ejemplo está etiquetado con una o más etiquetas de manera simultánea.

Instance	Features	Labels				
		λ_1	λ_2	λ_3	...	λ_q
#1	$\mathbf{x}_1$	0	1	0	...	0
#2	$\mathbf{x}_2$	1	0	1	...	1
#3	$\mathbf{x}_3$	0	1	0	...	1
#4	$\mathbf{x}_4$	0	1	0	...	0
#5	$\mathbf{x}_5$	0	1	1	...	0
...	...			...		
#m	$\mathbf{x}_m$	1	0	1	...	1

Figura 2.4: Ejemplo de conjunto de datos multi-etiqueta obtenido de [1]

El objetivo del MLC es construir un modelo predictivo $h : \mathcal{X} \to 2^{\mathcal{Y}}$ que ofrezca un conjunto de etiquetas relevantes para una instancia desconocida. Por tanto, para cada $x \in \mathcal{X}$, una bipartición $\hat{b} = (\hat{Y}, \overline{\hat{Y}})$ del espacio de etiquetas $\mathcal{Y}$ es dado, donde $\hat{Y} = h(x)$ es el conjunto de etiquetas relevantes e $\overline{\hat{Y}}$ el conjunto de irrelevantes. Esta bipartición también se puede dar como un vector binario $\hat{b} = \{0, 1\}^q$, indicando si cada etiqueta es relevante (1) o no (0).

Además, vamos a definir un Grupo de Clasificadores Multi-Etiqueta como un conjunto de n clasificadores multi-etiqueta. Cada uno de los clasificadores base h_j da una predicción $\hat{b_j} = \{\hat{b_{j1}}, \hat{b_{j2}}, \ldots, \hat{b_{jq}}\}$ para todas (o parte) de las etiquetas, siendo cada b_j 1 si la etiqueta es relevante y 0 si no lo es. La predicción final del conjunto suele ser calculada mediante el valor medio de las predicciones para cada etiqueta $\hat{v_l} = \frac{1}{n} \sum_{j=1}^{n} \hat{b_{jl}}$. Sin embargo, hay otros métodos a parte de simplemente votar para combinar las predicciones en el conjunto.

2.2.2. Eligiendo modelo para clasificación multi-etiqueta

Para la implementación de un clasificador multi-etiqueta debemos elegir qué arquitectura de red usaremos. Vamos a revisar las opciones que tenemos, por ejemplo en [9] se analiza el cambio de paradigma en el problema que han traído los sistemas basados en redes convolucionales y transformers y estudia como diferentes métodos derivados de estas redes han mejorado la calidad de los sistemas de aprendizaje para esta tarea. Podemos encontrar un benchmarking de diferentes arquitecturas de redes como ResNet101 [10], ViT-Base [11], ML-GCN [12], ASL [13], Q2L [14], SALGL [15], SGRE [16], and PAT [17]. Por simplicidad y su uso tan extendido usaremos ResNet en nuestra implementación.

En cuanto a la resolución del problema conjunto de crear un clasificador multi-etiqueta dentro de un entorno federado, como ya hemos visto anteriormente hay estudios que se centran en evitar el problema haciendo un tratamiento previo de los datos para evitar el desbalanceo, otros estudian diferentes arquitecturas de la red como Transformer-based Federated Learning for Multi-Label Remote Sensing Image Classification [18]. Sin embargo estos estudios comparten la misma red entre los clientes o se aplican sobre datos tabulados. Nuestra propuesta requiere que la distribución de los datos contenga diferente número de etiquetas y que el sistema acepte una arquitectura con diferentes redes, no hemos encontrado ningún estudio que una todos estos conceptos en una solución.

3. Federación con capas personalizadas y salidas heterogéneas (FedPerH)

En esta sección vamos a definir el problema que debemos solucionar, concretaremos las herramientas que usaremos basándonos en el estado del arte de la sección anterior y describiremos la arquitectura que hemos propuesto para la solución de dicho problema.

3.1. Datos de entrenamiento

Para los datos de entrenamiento vamos a usar el conjunto de imágenes multietiqueta Corel-5k, que tiene 5000 imágenes de 50 categorías y un diccionario de 260 palabras o clases `https://www.kaggle.com/datasets/parhamsalar/corel5k`.

El dataset se compone de una carpeta con las 5000 imágenes y tres archivos csv que asignan las etiquetas a cada nombre de imagen. Lo primero que hacemos es componer tres DataFrame de Pandas, uno por cada archivo csv de manera que para cada elemento en la columna "`image_name`"tiene las imágenes en formato PIL y en la columna "`image_labels`"tiene una lista con el nombre de cada etiqueta de esa imagen. Luego los unimos en un único DataFrame ya que es más cómodo trabajar con todos los datos juntos.

Una vez tenemos un único DataFrame el siguiente paso es separarlo en dos de manera que tengamos dos conjuntos de datos con etiquetas diferentes, para ello primero contamos el número de etiquetas totales del dataset y lo ordenamos por las que más se repiten, en nuestro caso son "waterz "sky". Creamos un subconjunto de ejemplos que contienen la etiqueta "waterz eliminamos de ese subconjunto todas las etiquetas "sky", de esta manera conseguimos que la etiqueta "sky"sea exclusiva

del segundo conjunto el cuál tendrá un procesado similar pero seleccionando los ejemplos que contengan "sky" eliminando la etiqueta "water".

Ya hemos conseguido dos DataFrame que contienen clases exclusivas, en este paso vamos a convertirlos al tipo Dataset para seguir trabajando con ellos y dividir cada uno en dos subconjuntos "train" "test."[en] una distribución de 80 y 20 %. Ahora tenemos un DataSet de imágenes y etiquetas en forma de palabras que vamos a cambiar para que sean números desde 0 hasta el número de etiquetas para el conjunto water y lo mismo para sky. Seleccionamos todas las etiquetas únicas de cada conjunto y las numeramos desde 0 hasta el tamaño del conjunto de etiquetas únicas -1 y luego aplicamos una transformación al DataSet para que intercambie cada etiqueta por su identificador.

Una vez tenemos el remapeo de etiquetas lo siguente es realizar transformaciones aleatorias sobre las imágenes para normalizarlas y para añadir varibilidad en el entrenamiento. Las operaciones que vamos a aplicar son reescalar a un tamaño de 32x32, volcado horizontal aleatorio, rotación aleatoria, recorte central, normalización y los conjuntos de etiquetas los vamos a poner en formato one-hot.

Por último vamos a configurar los DataLoaders que serán los conjuntos que se van a usar para el entrenamiento y la evaluación ajustando el formato para que tenga un diccionario con todas las imágenes en "`image_name`" todas las etiquetas en one-hot en "`image_name`".

Con estos DataLoaders podemos empezar a trabajar.

3.2. Arquitectura de la solución

3.3. Métricas

4. Estudio experimental

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Mauris id tortor eget tellus sollicitudin molestie. Morbi vehicula aliquam turpis, eget efficitur dolor rhoncus non. Integer mi odio, elementum non euismod sed, elementum eu dolor. Maecenas commodo sapien sed ultricies posuere. Ut molestie, mauris et tempor fermentum, ex massa consequat elit, eu consequat justo nibh ut augue. Sed in justo dui. Sed non molestie nisi. Ut fermentum nec ante sed ultrices. Vestibulum placerat quam urna, nec sollicitudin nibh rhoncus non. Curabitur pulvinar facilisis posuere.

4.1. Configuración de los experimentos

Donec eu dolor et quam porta vulputate vitae vulputate augue. Etiam fermentum, lectus vitae euismod feugiat, elit ligula luctus ante, eget commodo turpis leo vel quam. Aenean consectetur in turpis sit amet varius. Sed porta porttitor lectus, id tempus nunc suscipit vitae. Etiam blandit quam quis magna ornare pharetra. Aenean eget tortor nisi. Sed sit amet tempus eros. Phasellus pretium, nunc nec fringilla placerat, metus lectus maximus eros, nec condimentum neque ex nec orci. Vivamus facilisis at turpis sit amet maximus. Ut dolor justo, bibendum eget rhoncus eget, malesuada malesuada lacus. Suspendisse potenti.

Donec augue nulla, semper ac tempor sit amet, vehicula sed est. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Pellentesque vel convallis justo, quis feugiat velit. Etiam fermentum, risus et venenatis rhoncus, ipsum ligula congue neque, sed consectetur arcu turpis vel metus. Integer ornare turpis et luctus ullamcorper. Ut placerat a ex et consequat. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas.

4.2. Análisis de resultados

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Mauris id tortor eget tellus sollicitudin molestie. Morbi vehicula aliquam turpis, eget efficitur dolor rhoncus non. Integer mi odio, elementum non euismod sed, elementum eu dolor. Maecenas commodo sapien sed ultricies posuere. Ut molestie, mauris et tempor fermentum, ex massa consequat elit, eu consequat justo nibh ut augue. Sed in justo dui. Sed non molestie nisi. Ut fermentum nec ante sed ultrices. Vestibulum placerat quam urna, nec sollicitudin nibh rhoncus non. Curabitur pulvinar facilisis posuere.

Donec eu dolor et quam porta vulputate vitae vulputate augue. Etiam fermentum, lectus vitae euismod feugiat, elit ligula luctus ante, eget commodo turpis leo vel quam. Aenean consectetur in turpis sit amet varius. Sed porta porttitor lectus, id tempus nunc suscipit vitae. Etiam blandit quam quis magna ornare pharetra. Aenean eget tortor nisi. Sed sit amet tempus eros. Phasellus pretium, nunc nec fringilla placerat, metus lectus maximus eros, nec condimentum neque ex nec orci. Vivamus facilisis at turpis sit amet maximus. Ut dolor justo, bibendum eget rhoncus eget, malesuada malesuada lacus. Suspendisse potenti.

Donec augue nulla, semper ac tempor sit amet, vehicula sed est. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Pellentesque vel convallis justo, quis feugiat velit. Etiam fermentum, risus et venenatis rhoncus, ipsum ligula congue neque, sed consectetur arcu turpis vel metus. Integer ornare turpis et luctus ullamcorper. Ut placerat a ex et consequat. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas.

5. Conclusiones y trabajo futuro

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Mauris id tortor eget tellus sollicitudin molestie. Morbi vehicula aliquam turpis, eget efficitur dolor rhoncus non. Integer mi odio, elementum non euismod sed, elementum eu dolor. Maecenas commodo sapien sed ultricies posuere. Ut molestie, mauris et tempor fermentum, ex massa consequat elit, eu consequat justo nibh ut augue. Sed in justo dui. Sed non molestie nisi. Ut fermentum nec ante sed ultrices. Vestibulum placerat quam urna, nec sollicitudin nibh rhoncus non. Curabitur pulvinar facilisis posuere.

5.1. Conclusiones

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Mauris id tortor eget tellus sollicitudin molestie. Morbi vehicula aliquam turpis, eget efficitur dolor rhoncus non. Integer mi odio, elementum non euismod sed, elementum eu dolor. Maecenas commodo sapien sed ultricies posuere. Ut molestie, mauris et tempor fermentum, ex massa consequat elit, eu consequat justo nibh ut augue. Sed in justo dui. Sed non molestie nisi. Ut fermentum nec ante sed ultrices. Vestibulum placerat quam urna, nec sollicitudin nibh rhoncus non. Curabitur pulvinar facilisis posuere.

Donec eu dolor et quam porta vulputate vitae vulputate augue. Etiam fermentum, lectus vitae euismod feugiat, elit ligula luctus ante, eget commodo turpis leo vel quam. Aenean consectetur in turpis sit amet varius. Sed porta porttitor lectus, id tempus nunc suscipit vitae. Etiam blandit quam quis magna ornare pharetra. Aenean eget tortor nisi. Sed sit amet tempus eros. Phasellus pretium, nunc nec fringilla placerat, metus lectus maximus eros, nec condimentum neque ex nec orci. Vivamus facilisis at turpis sit amet maximus. Ut dolor justo, bibendum eget rhoncus eget, malesuada malesuada lacus. Suspendisse potenti.

Donec augue nulla, semper ac tempor sit amet, vehicula sed est. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Pellentesque vel convallis justo, quis feugiat velit. Etiam fermentum, risus et venenatis rhoncus, ipsum ligula congue neque,

sed consectetur arcu turpis vel metus. Integer ornare turpis et luctus ullamcorper. Ut placerat a ex et consequat. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas.

5.2. Trabajo futuro

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Mauris id tortor eget tellus sollicitudin molestie. Morbi vehicula aliquam turpis, eget efficitur dolor rhoncus non. Integer mi odio, elementum non euismod sed, elementum eu dolor. Maecenas commodo sapien sed ultricies posuere. Ut molestie, mauris et tempor fermentum, ex massa consequat elit, eu consequat justo nibh ut augue. Sed in justo dui. Sed non molestie nisi. Ut fermentum nec ante sed ultrices. Vestibulum placerat quam urna, nec sollicitudin nibh rhoncus non. Curabitur pulvinar facilisis posuere.

Donec eu dolor et quam porta vulputate vitae vulputate augue. Etiam fermentum, lectus vitae euismod feugiat, elit ligula luctus ante, eget commodo turpis leo vel quam. Aenean consectetur in turpis sit amet varius. Sed porta porttitor lectus, id tempus nunc suscipit vitae. Etiam blandit quam quis magna ornare pharetra. Aenean eget tortor nisi. Sed sit amet tempus eros. Phasellus pretium, nunc nec fringilla placerat, metus lectus maximus eros, nec condimentum neque ex nec orci. Vivamus facilisis at turpis sit amet maximus. Ut dolor justo, bibendum eget rhoncus eget, malesuada malesuada lacus. Suspendisse potenti.

Bibliografía

[1] Jose M. Moyano. Multi-label classification models for heterogeneous data: an ensemble-based approach, 2020.

[2] Qiang Yang, Yang Liu, Yong Cheng, Yan Kang, Tianjian Chen, and Han Yu. *Federated Learning*. Morgan & Claypool publishers, 2019.

[3] H. Brendan McMahan, Eider Moore, Daniel Ramage, Seth Hampson, and Blaise Agüera y Arcas. Communication-efficient learning of deep networks from decentralized data. 2023.

[4] Mang Ye, Xiuwen Fang, Bo Du, Pong C. Yuen, and Dacheng Tao. Heterogeneous federated learning: State-of-the-art and research challenges. *ACM Comput. Surv.*, 56(3), October 2023.

[5] Yue Zhao, Meng Li, Liangzhen Lai, Naveen Suda, Damon Civin, and Vikas Chandra. Federated learning with non-iid data. 2018.

[6] Marcos F. Criado, Fernando E. Casado, Roberto Iglesias, Carlos V. Regueiro, and Senén Barro. Non-iid data and continual learning processes in federated learning: A long road ahead. 2021.

[7] Zhaobin Sun, Nannan Wu, Junjie Shi, Li Yu, Xin Yang, Kwang-Ting Cheng, and Zengqiang Yan. Fedmlp: Federated multi-label medical image classification under task heterogeneity. 2024.

[8] Manoj Ghuhan Arivazhagan, Vinay Aggarwal, Aaditya Kumar Singh, and Sunav Choudhary. Federated learning with personalization layers. 2019.

[9] Xuelin Zhu, Xiu-Shen Wei, Jiawei Ge, Shuai Xu, and Bing Wang. Rethinking multi-label image classification with deep learning: Taxonomy, challenge, and outlook. 2026.

[10] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. 2015.

[11] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer,

Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. 2021.

[12] Zhao-Min Chen, Xiu-Shen Wei, Peng Wang, and Yanwen Guo. Multi-label image recognition with graph convolutional networks. 2019.

[13] Emanuel Ben-Baruch, Tal Ridnik, Nadav Zamir, Asaf Noy, Itamar Friedman, Matan Protter, and Lihi Zelnik-Manor. Asymmetric loss for multi-label classification. 2021.

[14] Shilong Liu, Lei Zhang, Xiao Yang, Hang Su, and Jun Zhu. Query2label: A simple transformer way to multi-label classification. 2021.

[15] Xuelin Zhu, Jian Liu, Weijia Liu, Jiawei Ge, Bo Liu, and Jiuxin Cao. Scene-aware label graph learning for multi-label image classification. pages 1473–1482, 2023.

[16] Xuelin Zhu, Jianshu Li, Jiuxin Cao, Dongqi Tang, Jian Liu, and Bo Liu. Semantic-guided representation enhancement for multi-label image classification. *IEEE Transactions on Circuits and Systems for Video Technology*, 34(10):10036–10049, 2024.

[17] Ming-Kun Xie, Jia-Hao Xiao, Pei Peng, Gang Niu, Masashi Sugiyama, and Sheng-Jun Huang. Counterfactual reasoning for multi-label image classification via patching-based training. 2024.

[18] Barış Büyüktaş, Kenneth Weitzel, Sebastian Völkers, Felix Zailskas, and Begüm Demir. Transformer-based federated learning for multi-label remote sensing image classification. 2024.